Pemodelan Bilinear Suhu Permukaan Laut Bulanan Wilayah Niño 3 dengan Komponen Musiman Fourier

Zaki Abiyu Aqilah
zakiabiqu@gmail.com

Abstrak

El Niño Southern Oscillation (ENSO) menghasilkan anomali suhu permukaan laut (SST) yang tidak simetris di Pasifik ekuator bagian timur, yaitu kejadian El Niño cenderung lebih kuat daripada La Niña. Asimetri tersebut tidak dapat dijelaskan oleh model linear dengan galat Gaussian sehingga diperlukan model nonlinear. Penelitian ini bertujuan memodelkan dan meramalkan SST bulanan wilayah Niño 3 periode Januari 1950 sampai Juni 2026 menggunakan model bilinear setelah komponen musimannya dihilangkan dengan deret Fourier. Komponen musiman terbaik berdasarkan BIC terdiri atas dua harmonik dan tren linear. Uji Lagrange multiplier menolak hipotesis kelinearan pada taraf nyata 5%. Sebanyak 832 model BL(p,r,m,k) dievaluasi menggunakan RMSE titik asal bergulir pada data latih, dan model BL(2,2,1,1) terpilih sebagai model dengan RMSE terkecil. Pada data uji, RMSE peramalan satu langkah ke depan model BL(2,2,1,1) sebesar 0,258 °C, lebih kecil daripada model ARMA(2,2), metode persistensi, dan metode klimatologi, serta setara dengan model AR(5). Pada bulan El Niño, model BL(2,2,1,1) menghasilkan RMSE terkecil di antara seluruh model pembanding. Hasil peramalan menggunakan seluruh data menunjukkan anomali positif yang mencapai puncak 1,97 °C pada Agustus 2026 lalu melemah menjadi 1,55 °C pada Desember 2026.

Kata Kunci *ENSO, Model Bilinear, Peramalan, Suhu Permukaan Laut*

1 Pendahuluan

El Niño Southern Oscillation (ENSO) merupakan fluktuasi tahunan terkuat dalam sistem iklim global yang berdampak pada iklim, ekosistem laut dan darat, perikanan, serta aktivitas manusia (Timmermann dkk. 2018). Kondisi ENSO umumnya dipantau melalui suhu permukaan laut (*sea surface temperature*, SST) di Pasifik ekuator, salah satunya di wilayah Niño 3 yang terletak pada 5°LU sampai 5°LS dan 90°BB sampai 150°BB (Trenberth 1997). Burgers dan Stephenson (1999) menunjukkan bahwa anomali SST di Pasifik timur memiliki kemencengan positif yang berkaitan dengan dominasi kejadian El Niño dibandingkan La Niña. Apabila ENSO dibangkitkan oleh sistem linear dengan derau Gaussian, anomali SST seharusnya berdistribusi normal (Burgers dan Stephenson 1999). Oleh karena itu, asimetri tersebut mengindikasikan adanya proses nonlinear.

Salah satu model deret waktu nonlinear adalah model bilinear yang diperkenalkan oleh Granger dan Andersen (1978a). Model ini memperluas model ARMA dengan menambahkan suku hasil kali antara nilai deret dan galat pada waktu sebelumnya. Subba Rao (1981) menurunkan syarat cukup stasioneritas, ragam dan kovarians, serta syarat invertibilitas model bilinear, kemudian menerapkannya pada data bilangan bintik matahari. Gabr dan Subba Rao (1981)

mengembangkan pendugaan dan peramalan model bilinear subset serta membandingkan hasil peramalannya dengan model AR linear dan model AR ambang.

Penelitian ini bertujuan memodelkan SST bulanan wilayah Niño 3 menggunakan model bilinear dengan komponen musiman Fourier. Identifikasi orde model disusun secara bertahap, pemilihan model dilakukan dengan evaluasi titik asal bergulir, dan ketepatan peramalan pada data uji dibandingkan dengan model AR serta dua metode pembanding sederhana. Model terpilih selanjutnya digunakan untuk meramalkan SST pada Juli sampai Desember 2026.

2 Metode

2.1 Data

Data yang digunakan dalam penelitian ini adalah SST bulanan wilayah Niño 3 periode Januari 1950 sampai Juni 2026 sebanyak 918 pengamatan yang diperoleh dari NOAA Climate Prediction Center. Data tersebut disusun dari Extended Reconstructed Sea Surface Temperature versi 5 (ERSSTv5), yaitu data SST global bulanan dengan resolusi $2^\circ \times 2^\circ$ (Huang dkk. 2017). Variabel yang digunakan adalah SST aktual, bukan anomali, sehingga komponen musiman dapat diduga hanya dari data latih. Data dibagi secara berurutan menjadi data latih sebanyak 780 pengamatan (85%, Januari 1950 sampai Desember 2014) dan data uji sebanyak 138 pengamatan (15%, Januari 2015 sampai Juni 2026). Tahap identifikasi, pendugaan parameter, dan pemilihan model hanya menggunakan data latih.

2.2 Komponen musiman

Deret SST X_t diuraikan menjadi komponen musiman S_t dan komponen stokastik Y_t sebagai berikut

$$X_t = S_t + Y_t, \qquad S_t = \mu + \delta \frac{t}{120} + \sum_{q=1}^{K} \left[\beta_q \sin\left(\frac{2\pi q t}{12}\right) + \lambda_q \cos\left(\frac{2\pi q t}{12}\right) \right], \tag{1}$$

dengan $t = 0,1,\ldots$ menyatakan indeks bulan sejak Januari 1950 sehingga δ menyatakan tren dalam °C per dekade. Deret Fourier dapat merepresentasikan pola musiman, termasuk pola musiman yang kompleks (De Livera dkk. 2011). Parameter komponen musiman diduga dengan metode kuadrat terkecil. Banyaknya harmonik $K \in \{1,\ldots,6\}$ dan penyertaan tren ditentukan berdasarkan nilai BIC terkecil. Kriteria ini memberikan penalti sebesar $\frac{1}{2}k \log n$ terhadap logaritma fungsi kemungkinan sehingga cenderung memilih model dengan dimensi lebih kecil dibandingkan kriteria Akaike (Schwarz 1978). Komponen musiman untuk periode data uji dan periode peramalan dihitung dari persamaan (1) menggunakan parameter yang sama.

2.3 Model bilinear

Model bilinear BL(p,r,m,k) untuk deret Y_t didefinisikan sebagai berikut (Granger dan Andersen 1978a, Subba Rao 1981, Subba Rao dan Gabr 1984)

$$Y_t + \sum_{u=1}^{p} a_u Y_{t-u} = \alpha + \sum_{l=1}^{r} c_l\, e_{t-l} + \sum_{i=1}^{m}\sum_{j=1}^{k} b_{ij}\, Y_{t-i}\, e_{t-j} + e_t, \tag{2}$$

dengan a_u, c_l, dan b_{ij} berturut-turut menyatakan koefisien bagian autoregresif (AR), rata-rata bergerak (MA), dan bilinear, α menyatakan konstanta, serta e_t menyatakan galat yang saling bebas dengan rataan nol dan ragam σ^2. Koefisien AR dituliskan pada ruas kiri sehingga $a_u = -\phi_u$ dalam notasi ARMA yang umum digunakan. Apabila seluruh b_{ij} bernilai nol, persamaan (2) tereduksi menjadi model ARMA(p,r). Gabr dan Subba Rao (1981) membahas bentuk subset yang hanya memuat lag tertentu pada setiap bagian model.

Suku MA dan suku bilinear pada lag galat yang sama dapat dituliskan sebagai

$$\left(c_l + \sum_{i=1}^{m} b_{il}\, Y_{t-i}\right) e_{t-l}.$$

Bentuk ini menunjukkan bahwa koefisien galat masa lalu bergantung pada nilai deret sebelumnya sehingga model bilinear dapat menghasilkan perilaku yang tidak simetris.

Granger dan Andersen (1978b) mengusulkan definisi invertibilitas yang lebih umum dan menerapkannya pada model linear, nonlinear, dan bilinear. Suatu model dikatakan invertibel apabila galat dapat direkonstruksi dari data pengamatan dan pengaruh kesalahan nilai awal galat menghilang seiring bertambahnya waktu. Pada penelitian ini, invertibilitas diperiksa secara numerik dengan merambatkan gangguan $d_t = 1$ untuk $t \le \gamma$ melalui rekursi

$$d_t = -\sum_{l=1}^{r} c_l\, d_{t-l} - \sum_{i=1}^{m}\sum_{j=1}^{k} b_{ij}\, Y_{t-i}\, d_{t-j}, \qquad t > \gamma. \tag{3}$$

Model dinyatakan invertibel apabila $\log_{10}|d_t| < 0$ pada akhir periode data.

2.4 Pendugaan parameter

Pendugaan parameter model bilinear dibahas oleh Subba Rao (1981) serta Gabr dan Subba Rao (1981). Pada penelitian ini, parameter $\boldsymbol{\theta} = (a,c,b,\alpha)$ diduga dengan metode kuadrat terkecil bersyarat. Galat dihitung secara rekursif berdasarkan persamaan (2) dengan nilai awal $e_t = 0$ untuk $t \le \gamma$, kemudian jumlah kuadrat galat

$$Q(\boldsymbol{\theta}) = \sum_{t=\gamma+1}^{N} e_t^2(\boldsymbol{\theta}) \tag{4}$$

diminimumkan menggunakan iterasi Gauss-Newton. Turunan $\partial e_t/\partial\boldsymbol{\theta}$ dihitung secara rekursif, dan setiap iterasi dilengkapi dengan pembagian langkah untuk menjamin penurunan nilai Q. Nilai $\gamma = 12$ digunakan untuk seluruh model sehingga setiap model diduga dengan $n = N - \gamma$ pengamatan yang sama dan nilai AIC antarmodel dapat dibandingkan. AIC dihitung sebagai

$n \log \hat{\sigma}^2 + 2q$ dengan q menyatakan banyaknya parameter (Akaike 1974). Iterasi dibatasi sebanyak 500 kali dan dilanjutkan dari dugaan terakhir hingga paling banyak 2.000 iterasi apabila belum konvergen.

2.5 Identifikasi orde

Stasioneritas deret Y_t diuji menggunakan uji Augmented Dickey-Fuller (ADF) dengan hipotesis nol bahwa deret memiliki akar unit (Dickey dan Fuller 1979, Said dan Dickey 1984) serta uji KPSS dengan hipotesis nol bahwa deret stasioner (Kwiatkowski dkk. 1992).

Orde bagian linear diidentifikasi berdasarkan fungsi autokorelasi (ACF), fungsi autokorelasi parsial (PACF), dan nilai AIC model AR. Kim (1992) menunjukkan bahwa ACF model bilinear BL(p,q,r,s) memiliki pola yang menyerupai ACF model ARMA(p,l) dengan $l = \max(q,s)$. Dengan demikian, ACF dan PACF tidak dapat membedakan bagian MA dari bagian bilinear sehingga Kim (1992) menyarankan pemilihan model di antara beberapa kandidat menggunakan AIC. Oleh karena itu, ACF dan PACF pada penelitian ini digunakan untuk menentukan kandidat orde, sedangkan model akhir ditentukan berdasarkan kriteria pada Subbab 2.6.

Keberadaan suku bilinear diuji menggunakan uji Lagrange multiplier (LM) terhadap alternatif bilinear (Saikkonen dan Luukkonen 1988). Statistik uji diperoleh melalui regresi bantu, yaitu residual model linear diregresikan terhadap regresor model linear dan suku hasil kali yang bersesuaian dengan suku bilinear. Teräsvirta (1994) menyarankan penggunaan versi F dari statistik tersebut untuk deret berukuran kecil karena ukuran ujinya lebih mendekati taraf nyata nominal. Uji LM tidak dapat disusun terhadap alternatif yang memuat $Y_{t-i}e_{t-j}$ dan $Y_{t-j}e_{t-i}$ secara bersamaan sehingga suku bilinear dibatasi pada $i \geq j$ (Bera dan Higgins 1993). Pasangan lag yang berperan diidentifikasi melalui korelasi antara residual model AR $\hat{e}_t$ dan $(Y_{t-i} - \bar{Y})\hat{e}_{t-j}$ untuk i,$j = 1,\ldots,12$ dengan batas signifikansi $\pm 1{,}96/\sqrt{n}$. Pendekatan lain untuk identifikasi suku bilinear antara lain menggunakan ACF kuadrat deret (Li 1984), momen orde tiga (Kumar 1986, Wu dan Shih 1992), serta algoritma genetika dengan kriteria AIC atau BIC (Chen dkk. 2001).

2.6 Pemilihan model

Kandidat model disusun dari kombinasi orde AR p berdasarkan lag PACF yang signifikan, orde MA $r = 0,1,\ldots,12$, serta bagian bilinear yang memuat seluruh koefisien b_{ij} dengan $i \leq m \leq 5$ dan $j \leq k \leq 3$, termasuk model tanpa suku bilinear. Kandidat yang tidak konvergen atau tidak invertibel dikeluarkan dari pemilihan.

Setiap kandidat dievaluasi menggunakan metode titik asal bergulir (*rolling origin*), yaitu titik asal peramalan diperbarui secara berurutan sehingga diperoleh sejumlah galat peramalan (Tashman 2000). Lima titik asal ditetapkan pada 120 bulan terakhir data latih, yaitu Desember 2004, 2006, 2008, 2010, dan 2012. Pada setiap titik asal, komponen musiman dan model diduga ulang menggunakan data hingga titik asal tersebut, kemudian dilakukan peramalan satu langkah ke depan secara bergulir untuk 24 bulan berikutnya. RMSE titik asal bergulir dihitung dari $5 \times 24 = 120$ galat peramalan tersebut.

Model dengan RMSE titik asal bergulir terkecil di antara kandidat yang konvergen dan invertibel dipilih sebagai model terbaik. Kriteria ini digunakan karena ACF dan PACF tidak

dapat menentukan orde MA pada model bilinear secara tegas (Kim 1992).

2.7 Pemeriksaan diagnostik

Kelayakan model diperiksa melalui uji Ljung-Box terhadap residual (Ljung dan Box 1978), uji McLeod-Li yang menerapkan statistik Ljung-Box pada kuadrat residual (McLeod dan Li 1983), serta uji kemencengan u_1 dan keruncingan u_2 untuk proses stokastik linear (Lomnicki 1961). Statistik gabungan $u_1^2 + u_2^2$ dibandingkan dengan distribusi χ_2^2. Seluruh uji menggunakan 12 lag.

2.8 Peramalan

Peramalan satu langkah ke depan dari model (2) dapat dihitung secara eksak sebagai berikut

$$\hat{Y}_{t+1|t} = \alpha - \sum_{u=1}^{p} a_u Y_{t+1-u} + \sum_{l=1}^{r} c_l \, e_{t+1-l} + \sum_{i=1}^{m} \sum_{j=1}^{k} b_{ij} \, Y_{t+1-i} \, e_{t+1-j}. \tag{5}$$

Untuk $h \geq 2$, suku $b_{ij} Y_{t+h-i} e_{t+h-j}$ dengan $i \leq j$ memuat hasil kali nilai deret dan galat yang tidak saling bebas sehingga nilai harapan bersyaratnya tidak sama dengan nol. Peramalan berantai yang mengganti galat masa depan dengan nol, selanjutnya disebut peramalan naif, mengabaikan kontribusi suku tersebut. Brown dan Mariano (1989) mengkaji beberapa jenis peramal untuk model nonlinear dinamis, yaitu peramal deterministik, peramal Monte Carlo, dan peramal yang menggunakan distribusi empiris residual. Pada penelitian ini, $E(Y_{t+h} \mid Y_1, \ldots, Y_t)$ dihitung menggunakan simulasi Monte Carlo. Sejumlah lintasan dibangkitkan dari model dengan $e_t \sim N(0, \hat{\sigma}^2)$ apabila uji normalitas tidak menolak H_0, kemudian nilai ramalan diperoleh dari rata-rata lintasan tersebut. Selang peramalan ditentukan dari kuantil empiris lintasan. Ramalan SST diperoleh sebagai $\hat{X}_{t+h} = S_{t+h} + \hat{Y}_{t+h}$.

Ketepatan peramalan pada data uji dievaluasi menggunakan peramalan satu langkah ke depan secara bergulir. Parameter model ditetapkan sesuai hasil pendugaan pada data latih, sedangkan setiap peramalan menggunakan data aktual hingga bulan sebelumnya. Model pembanding yang digunakan adalah ARMA(2,2) sebagai bagian linear dari model terpilih, AR(5) sebagai model AR dengan AIC terkecil, metode persistensi ($\hat{Y}_{t+1} = Y_t$), dan metode klimatologi ($\hat{Y}_{t+1} = 0$, yaitu komponen musiman saja). Ukuran ketepatan yang digunakan adalah akar rata-rata kuadrat galat (RMSE) dan rata-rata galat mutlak (MAE). Ketepatan pada data uji juga dihitung secara terpisah untuk bulan El Niño, yaitu bulan dengan $Y_t > 1\,^{\circ}\text{C}$. Selain itu, peramalan berantai dari akhir data latih untuk $h = 1, \ldots, 138$ dilakukan untuk mengamati perilaku peramalan jangka panjang.

2.9 Tahapan analisis

Tahapan analisis dalam penelitian ini adalah sebagai berikut.

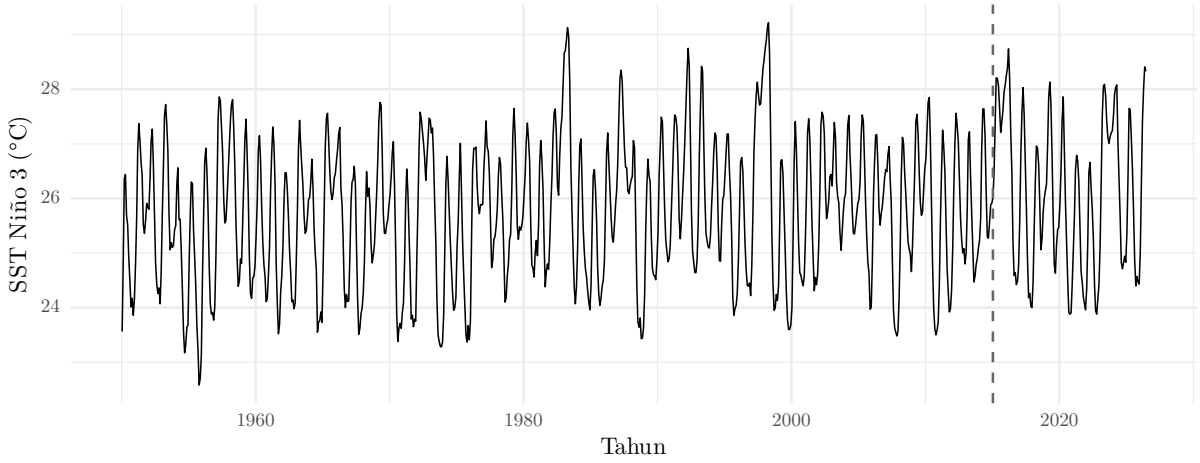
1. Membagi data menjadi data latih dan data uji secara berurutan.
2. Menduga komponen musiman pada data latih serta menentukan banyaknya harmonik dan penyertaan tren berdasarkan BIC.
3. Menguji stasioneritas deret Y_t.

4. Mengidentifikasi kandidat orde model berdasarkan ACF, PACF, AIC model AR, uji LM, dan korelasi suku bilinear.
5. Menduga parameter seluruh kandidat model dan menghitung RMSE titik asal bergulir.
6. Memilih model berdasarkan kriteria pada Subbab 2.6.
7. Menduga ulang parameter model terpilih serta memeriksa invertibilitas dan stasioneritas bagian AR.
8. Melakukan pemeriksaan diagnostik terhadap residual.
9. Mengevaluasi ketepatan peramalan pada data uji.
10. Menduga ulang model menggunakan seluruh data dan meramalkan SST pada Juli sampai Desember 2026.

3 Hasil dan Pembahasan

3.1 Deskripsi data

SST wilayah Niño 3 selama periode pengamatan berkisar antara 22,58 °C dan 29,22 °C dengan rata-rata 25,79 °C. Gambar 1 menunjukkan pola tahunan yang jelas disertai penyimpangan antartahunan yang berkaitan dengan ENSO. Penyimpangan positif terbesar terjadi pada akhir 1997, akhir 1982 hingga awal 1983, dan akhir 2015. Kenaikan SST pada periode tersebut tampak lebih tajam dibandingkan penurunannya, sejalan dengan asimetri yang dilaporkan oleh Burgers dan Stephenson (1999).



Gambar 1. SST bulanan wilayah Niño 3 periode Januari 1950 sampai Juni 2026. Garis putus-putus menunjukkan batas antara data latih dan data uji.

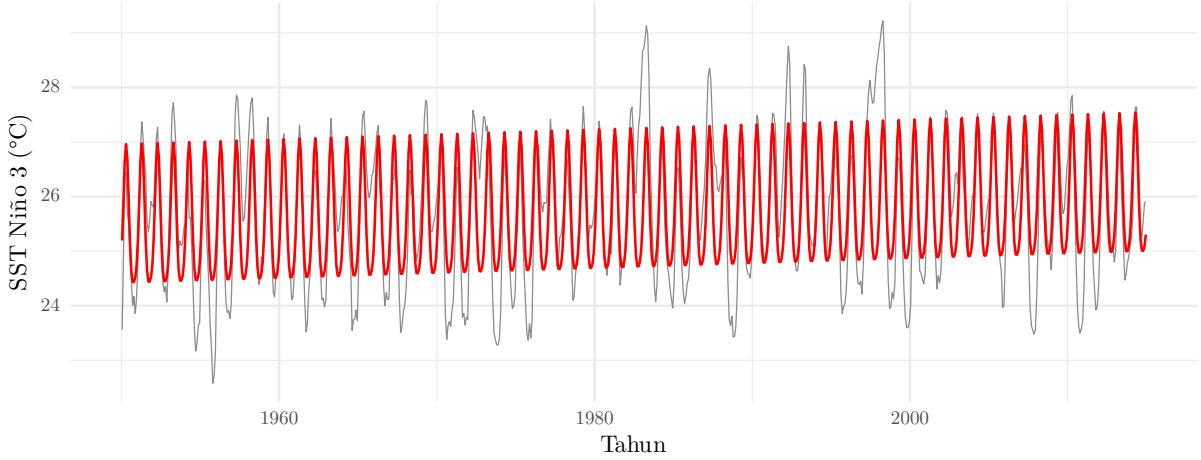
3.2 Komponen musiman

Berdasarkan Tabel 1, nilai BIC terkecil diperoleh pada model dengan $K = 2$ dan tren. Untuk setiap nilai K, model dengan tren selalu menghasilkan BIC yang lebih kecil daripada model tanpa tren. Dugaan koefisien tren sebesar 0,090 °C per dekade dengan galat baku 0,017. Amplitudo harmonik tahunan sebesar 1,27 °C, jauh lebih besar daripada amplitudo harmonik setengah

Tabel 1. Selisih BIC terhadap nilai terkecil berdasarkan banyaknya harmonik K dan penyertaan tren.

Model	$K=1$	$K=2$	$K=3$	$K=4$	$K=5$	$K=6$
Tanpa tren	42,2	22,6	34,7	47,7	60,9	74,0
Dengan tren	20,5	**0,0**	12,0	25,0	38,2	51,4

tahunan sebesar 0,26 °C. Komponen musiman menjelaskan 53,7% keragaman SST pada data latih (Gambar 2), sedangkan keragaman selebihnya dimodelkan melalui komponen stokastik Y_t.



Gambar 2. SST pada data latih (abu-abu) dan komponen musiman dengan $K = 2$ dan tren (merah).

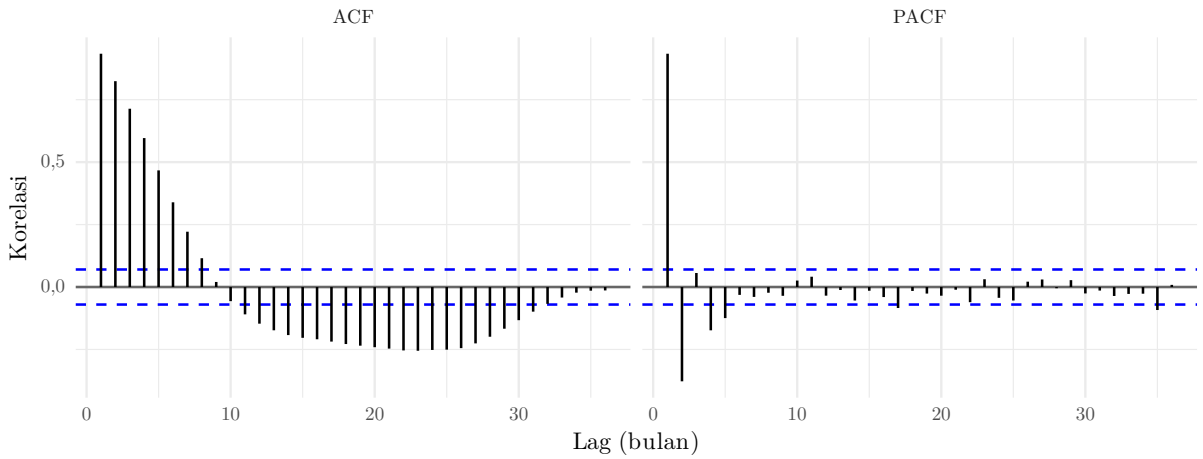
3.3 Identifikasi orde

Uji ADF menghasilkan statistik uji sebesar $-7{,}64$ dengan nilai-p kurang dari 0,01 sehingga hipotesis nol adanya akar unit ditolak. Uji KPSS menghasilkan statistik uji sebesar 0,070 dengan nilai-p lebih dari 0,10 sehingga hipotesis nol stasioneritas tidak ditolak. Kedua uji memberikan kesimpulan yang sama, yaitu deret Y_t stasioner sehingga tidak diperlukan pembedaan.

Gambar 3 menunjukkan ACF yang menurun secara perlahan dan PACF yang signifikan pada lag 1, 2, 4, dan 5. Nilai PACF pada lag 1 sebesar 0,934 dan pada lag 2 sebesar $-0{,}378$. Berdasarkan lag PACF yang signifikan, kandidat orde AR yang digunakan adalah $p \in \{1,2,4,5\}$. Pola ACF dan PACF tersebut mengindikasikan model AR. Namun, karena ACF dan PACF tidak dapat membedakan bagian MA dari bagian bilinear (Kim 1992), orde MA $r = 0,1,\ldots,12$ tetap disertakan sebagai kandidat. Di antara model AR(1) sampai AR(12) dengan $\gamma = 12$, nilai AIC terkecil diperoleh pada model AR(5). Selisih AIC model AR(4), AR(2), dan AR(1) terhadap model AR(5) berturut-turut sebesar 7,8, 28,4, dan 167,5.

Uji LM dilakukan untuk setiap kandidat orde AR, yaitu AR(1), AR(2), AR(4), dan AR(5), sebagai model nol. Regresor tambahan yang digunakan adalah $Y_{t-i}\hat{e}_{t-1}$ untuk $i = 1,\ldots,5$. Hasil uji disajikan pada Tabel 2. Seluruh model nol menghasilkan nilai-p kurang dari 0,001 sehingga hipotesis kelinearan ditolak pada taraf nyata 5%. Dengan demikian, suku bilinear diperlukan untuk setiap kandidat orde AR.

Gambar 4 memperlihatkan 14 dari 144 pasangan (i,j) yang melewati batas $\pm 0{,}071$. Pasangan yang paling menonjol berada pada kolom $j = 1$ dengan $i = 1,\ldots,5$, dengan korelasi terbesar



Gambar 3. ACF dan PACF deret Y_t pada data latih hingga lag 36. Garis putus-putus menunjukkan batas $\pm 1{,}96/\sqrt{n}$.

Tabel 2. Hasil uji Lagrange multiplier (versi F) terhadap alternatif bilinear.

Model nol	F	db_1	db_2	Nilai-p
AR(1)	7,167	5	761	$< 0{,}001$
AR(2)	6,233	5	760	$< 0{,}001$
AR(4)	7,045	5	758	$< 0{,}001$
AR(5)	6,597	5	757	$< 0{,}001$

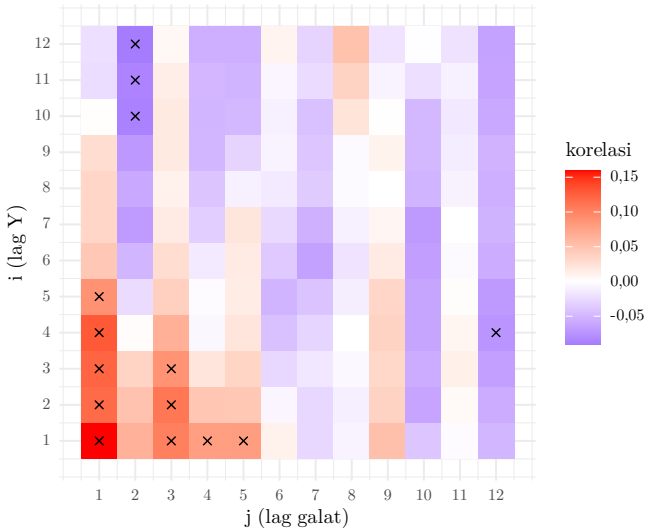
sebesar 0,159 pada pasangan (1,1). Seluruh pasangan dalam kelompok tersebut memenuhi syarat $i \geq j$. Pasangan signifikan lainnya tersebar dan sebagian berada pada daerah $i < j$, misalnya (1,3) dan (2,3). Dari 144 pengujian pada taraf nyata 5%, sekitar tujuh pasangan diperkirakan signifikan secara kebetulan. Berdasarkan hasil tersebut, kandidat bagian bilinear dibatasi pada $m \leq 5$ dan $k \leq 3$.

3.4 Pemilihan model

Kombinasi $p \in \{1,2,4,5\}$, $r \in \{0,\ldots,12\}$, dan 16 bentuk bagian bilinear menghasilkan 832 model kandidat. Sebanyak 43 model memerlukan iterasi lanjutan. Dari seluruh kandidat, 736 model memenuhi syarat konvergensi dan invertibilitas, 91 model tidak invertibel, dan 5 model tidak konvergen. Model yang tidak memenuhi syarat terkonsentrasi pada orde MA yang tinggi. Pada $r = 11$ dan $r = 12$, sebanyak 60 dari 128 model tidak memenuhi syarat.

Tabel 3 menyajikan sepuluh model dengan RMSE titik asal bergulir terkecil. RMSE terkecil sebesar 0,2420 dihasilkan oleh model BL(2,2,1,1) sehingga model tersebut dipilih sebagai model terbaik. Model ini memuat bagian MA berorde dua walaupun pola ACF dan PACF mengindikasikan model AR. Hal ini dapat dijelaskan oleh kemampuan model ARMA berorde rendah dalam mendekati model AR berorde lebih tinggi. Pada data latih, model ARMA(2,2) dengan lima parameter menghasilkan AIC sebesar $-2009{,}9$, lebih kecil daripada model AR(5) dengan enam parameter yang menghasilkan AIC sebesar $-2008{,}2$. Penambahan suku bilinear b_{11} pada model ARMA(2,2) menurunkan AIC menjadi $-2033{,}0$.

Gambar 5 menyajikan RMSE terkecil untuk setiap pasangan (p,r). Untuk $p = 2$, RMSE



Gambar 4. Korelasi antara residual model AR(5) $\hat{e}_t$ dan $(Y_{t-i} - \bar{Y})\hat{e}_{t-j}$. Tanda silang menunjukkan korelasi yang melewati batas $\pm 1{,}96/\sqrt{n}$.

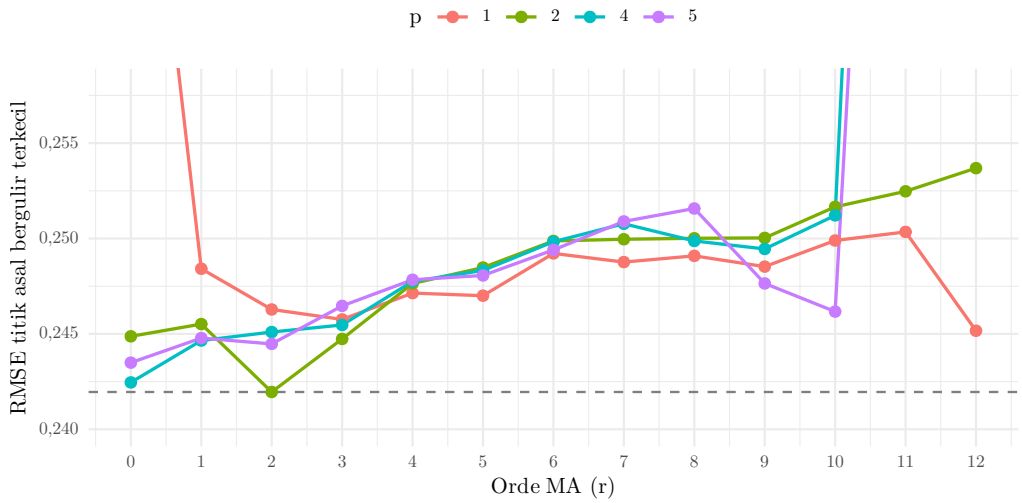
Tabel 3. Sepuluh model dengan RMSE titik asal bergulir terkecil. Model terpilih dicetak tebal.

Peringkat	Model	Banyak parameter	AIC	RMSE (°C)
1	**BL(2,2,1,1)**	6	−2033,0	0,2420
2	BL(4,0,5,1)	10	−2028,1	0,2425
3	BL(2,2,1,3)	8	−2031,3	0,2428
4	BL(2,2,1,2)	7	−2032,3	0,2430
5	BL(2,2,2,1)	7	−2031,6	0,2431
6	BL(2,2,5,1)	10	−2029,3	0,2431
7	BL(5,0,5,1)	11	−2033,9	0,2435
8	BL(2,2,4,1)	9	−2030,1	0,2437
9	BL(2,2,3,1)	8	−2031,8	0,2440
10	BL(4,0,0,0)	5	−2000,5	0,2441

terkecil dicapai pada $r = 2$, sedangkan penambahan orde MA di atas dua tidak meningkatkan ketepatan peramalan. Untuk $p = 4$ dan $p = 5$, RMSE terkecil cenderung meningkat dari $r = 0$ hingga $r = 8$. Pada $r = 11$ dan $r = 12$, RMSE meningkat tajam hingga di atas 0,31 karena hanya satu dari 16 model pada setiap pasangan tersebut yang memenuhi syarat. Selain itu, nilai AIC tidak selalu sejalan dengan ketepatan peramalan. Nilai AIC terkecil dimiliki oleh model BL(2,8,4,2) sebesar −2043,8, tetapi model tersebut memiliki RMSE sebesar 0,292 dan berada pada peringkat 716 dari 736. Hal ini menunjukkan bahwa penambahan parameter MA dan bilinear dapat meningkatkan kesesuaian model terhadap data latih tanpa meningkatkan ketepatan peramalan.

3.5 Pendugaan parameter model BL(2,2,1,1)

Hasil pendugaan parameter disajikan pada Tabel 4. Pendugaan dengan nilai awal bertahap dan nilai awal nol menghasilkan nilai AIC yang sama, yaitu −2033,02, dan konvergen dalam 13



Gambar 5. RMSE titik asal bergulir terkecil untuk setiap pasangan (p,r). Garis putus-putus menunjukkan nilai terkecil dari seluruh model. Sumbu vertikal dibatasi hingga 0,258.

Tabel 4. Hasil pendugaan parameter model BL(2,2,1,1) pada data latih.

Parameter	Dugaan	Galat baku	z	Nilai-p
a_1	−1,7161	0,0482	−35,59	< 0,001
a_2	0,7520	0,0425	17,70	< 0,001
c_1	−0,3523	0,0589	−5,98	< 0,001
c_2	−0,2564	0,0460	−5,58	< 0,001
b_{11}	0,2187	0,0368	5,95	< 0,001
α	−0,0134	0,0045	−2,97	0,003

iterasi. Model dugaan yang diperoleh adalah

$$\hat{Y}_t = 1{,}716\, Y_{t-1} - 0{,}752\, Y_{t-2} - 0{,}013 - 0{,}352\, e_{t-1} - 0{,}256\, e_{t-2} + 0{,}219\, Y_{t-1} e_{t-1},$$

dengan $\hat{\sigma}^2 = 0{,}0698$.

Berdasarkan pemeriksaan pada persamaan (3), model tersebut invertibel. Akar polinomial AR $1 + a_1 z + a_2 z^2$ berupa sepasang bilangan kompleks dengan modulus 1,153, sedangkan akar polinomial MA $1 + c_1 z + c_2 z^2$ memiliki modulus 1,404 dan 2,778. Seluruh modulus lebih besar dari satu sehingga bagian AR bersifat stasioner dan bagian MA bersifat invertibel. Akar AR kompleks tersebut berkaitan dengan siklus teredam dengan periode sekitar 43 bulan atau 3,6 tahun. Periode tersebut sesuai dengan karakteristik ENSO yang berulang setiap beberapa tahun (Timmermann dkk. 2018).

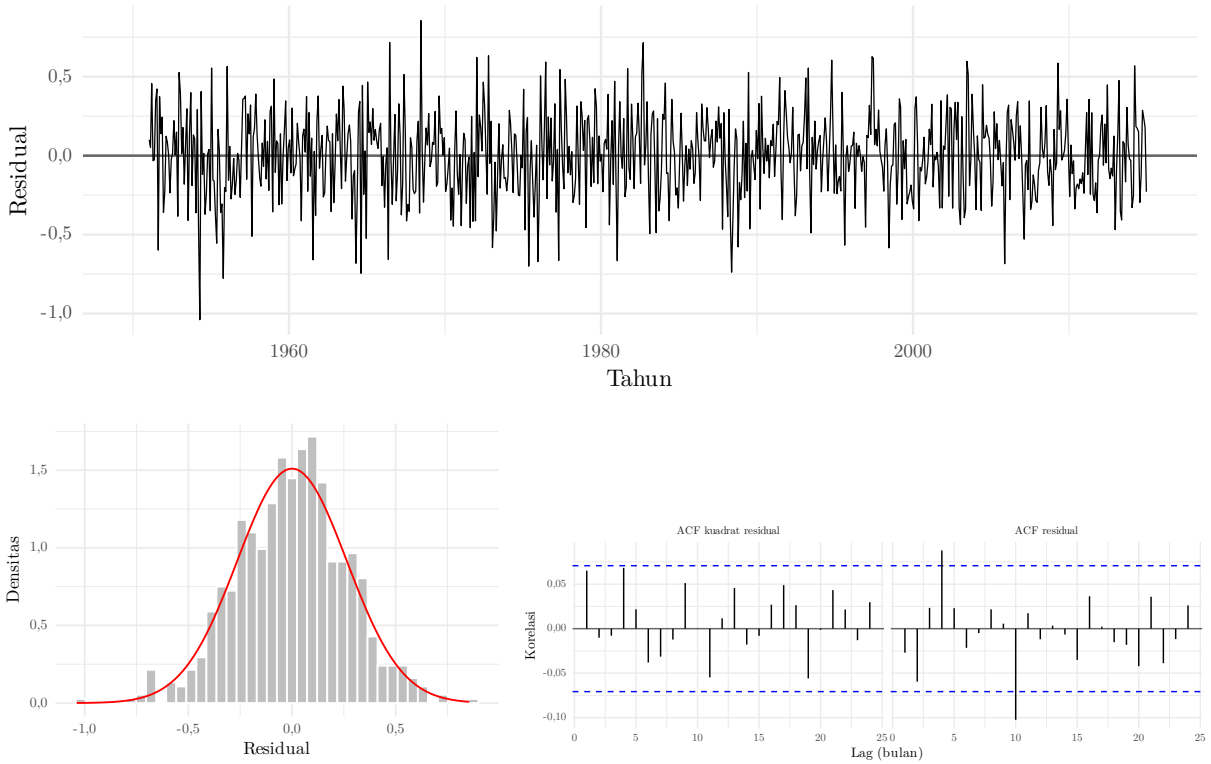
Seluruh parameter signifikan pada taraf nyata 5%. Galat baku koefisien bilinear dihitung dengan pendekatan $\hat{\sigma}^2 (J'J)^{-1}$ yang berpotensi menghasilkan nilai yang terlalu kecil sehingga nilai-p untuk b_{11} perlu ditafsirkan secara hati-hati. Koefisien efektif galat e_{t-1} adalah $c_1 + b_{11} Y_{t-1} = -0{,}352 + 0{,}219\, Y_{t-1}$. Koefisien efektif tersebut bernilai negatif ketika $Y_{t-1} < 1{,}61$ °C sehingga galat bulan sebelumnya diredam, dan bernilai positif ketika anomali bulan sebelumnya melebihi 1,61 °C sehingga galat positif diperkuat. Mekanisme ini sejalan dengan karakteristik El Niño kuat yang berkembang lebih tajam dibandingkan La Niña.

3.6 Pemeriksaan diagnostik

Tabel 5. Hasil pemeriksaan diagnostik residual model BL(2,2,1,1) pada data latih.

Uji	Statistik uji	Nilai-p
Ljung-Box pada residual (lag 12)	19,392	0,013
McLeod-Li pada kuadrat residual (lag 12)	13,864	0,309
Kemencengan u_1	$-1{,}471$	0,141
Keruncingan u_2	1,246	0,213
Normalitas $u_1^2 + u_2^2$	3,716	0,156

Hasil pemeriksaan diagnostik disajikan pada Tabel 5 dan Gambar 6. Uji normalitas tidak menolak H_0 dengan nilai-p sebesar 0,156, kemencengan sebesar $-0{,}133$, dan kelebihan keruncingan sebesar 0,220 sehingga simulasi Monte Carlo menggunakan galat berdistribusi normal. Uji McLeod-Li tidak menolak H_0 dengan nilai-p sebesar 0,309 sehingga tidak terdapat ketergantungan pada kuadrat residual. Uji Ljung-Box menolak H_0 pada taraf nyata 5% dengan nilai-p sebesar 0,013. ACF residual pada Gambar 6 menunjukkan bahwa autokorelasi yang tersisa bernilai kecil, tetapi model belum sepenuhnya menangkap struktur autokorelasi linear.

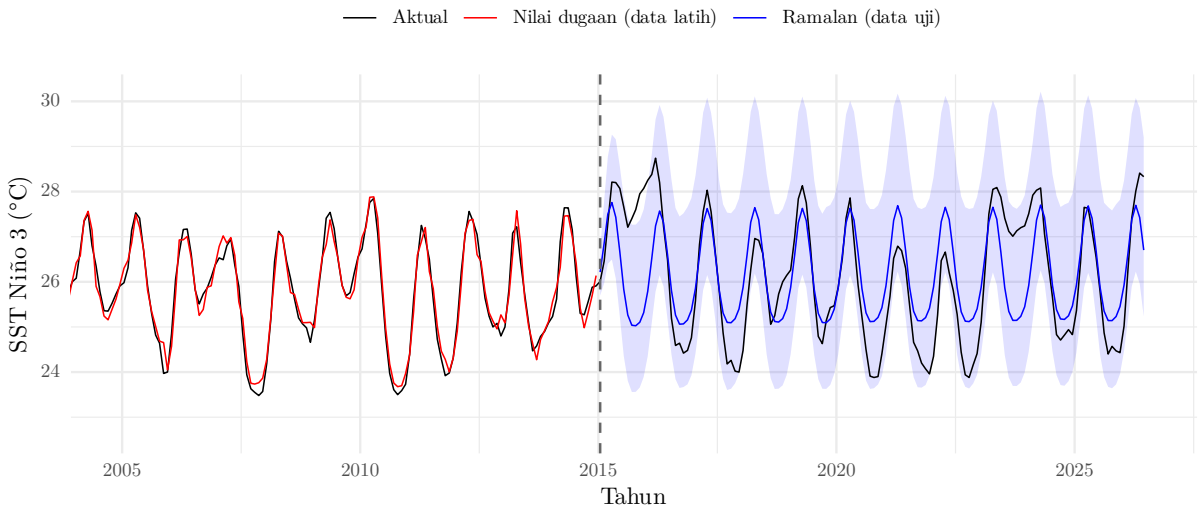


Gambar 6. Residual model BL(2,2,1,1) pada data latih. Bagian atas menunjukkan plot residual terhadap waktu, bagian kiri bawah menunjukkan histogram residual dengan densitas $N(0,\hat{\sigma}^2)$ (merah), dan bagian kanan bawah menunjukkan ACF residual dan ACF kuadrat residual.

3.7 Evaluasi peramalan pada data uji

Gambar 7 menyajikan nilai dugaan pada data latih dan hasil peramalan berantai untuk $h = 1,\ldots,138$ dari Desember 2014. Nilai dugaan mengikuti pola data aktual dengan baik. Hasil

peramalan jangka panjang kembali ke komponen musiman dalam beberapa bulan karena deret Y_t stasioner dengan rataan mendekati nol. Akibatnya, RMSE peramalan jangka panjang sebesar 0,986 °C hampir sama dengan RMSE komponen musiman sebesar 0,980 °C. Sebanyak 95,7% data uji berada di dalam selang peramalan 95%. Hasil ini menunjukkan bahwa peramalan dari satu titik asal hanya informatif untuk beberapa bulan pertama.



Gambar 7. Data aktual (hitam), nilai dugaan pada data latih (merah), dan hasil peramalan berantai pada data uji (biru) dengan selang peramalan 95% (pita biru) periode 2005 sampai 2026.

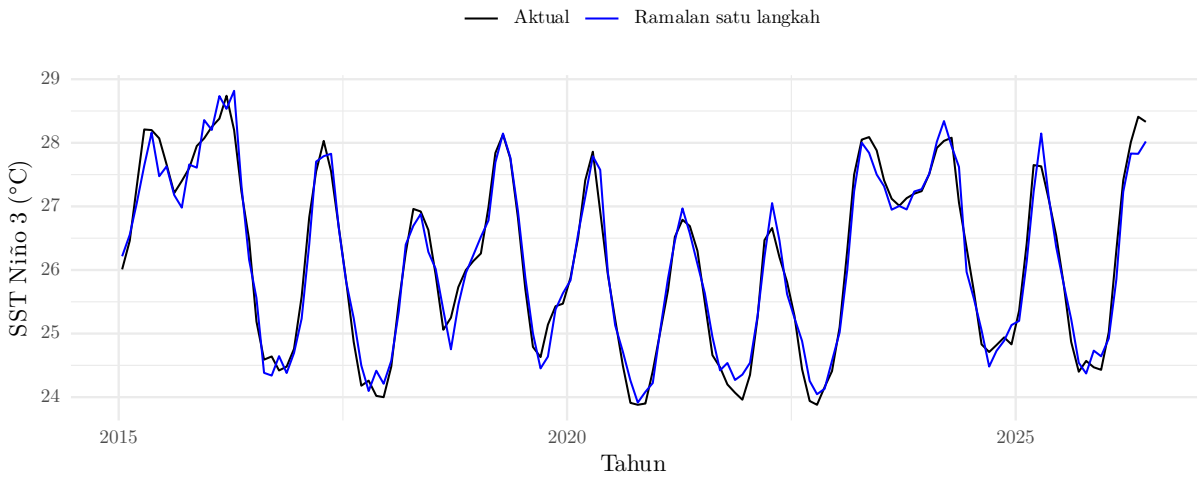
Tabel 6. Ketepatan peramalan satu langkah ke depan secara bergulir pada data uji (°C). Kolom El Niño menggunakan 21 bulan dengan $Y_t > 1\,°\text{C}$.

	Seluruh bulan		RMSE menurut kondisi	
Metode	RMSE	MAE	El Niño	Lainnya
BL(2,2,1,1)	0,2580	0,2095	0,2731	0,2552
ARMA(2,2)	0,2625	0,2133	0,2968	0,2559
AR(5)	0,2564	0,2097	0,2868	0,2506
Persistensi	0,3117	0,2535		
Klimatologi	0,9804	0,7628		

Ketepatan peramalan satu langkah ke depan secara bergulir disajikan pada Tabel 6. Model BL(2,2,1,1) menghasilkan RMSE sebesar 0,2580 °C. Nilai tersebut 17% lebih kecil daripada metode persistensi, 74% lebih kecil daripada metode klimatologi, dan 1,7% lebih kecil daripada model ARMA(2,2) yang merupakan bagian linearnya. Dibandingkan dengan model AR(5), RMSE model BL(2,2,1,1) lebih besar 0,6% sehingga ketepatan kedua model dapat dipandang setara. Gambar 8 menunjukkan bahwa hasil peramalan satu langkah ke depan mengikuti data aktual dengan baik, termasuk pada puncak El Niño 2015 sampai 2016 dan 2023 sampai 2024.

Perbedaan yang lebih jelas terlihat pada bulan El Niño, yaitu Juni 2015 sampai Maret 2016, Juni 2023 sampai Februari 2024, serta Mei dan Juni 2026. Pada bulan-bulan tersebut, model BL(2,2,1,1) menghasilkan RMSE sebesar 0,2731 °C, 8,0% lebih kecil daripada model ARMA(2,2) dan 4,8% lebih kecil daripada model AR(5). Sebaliknya, pada bulan lainnya model AR(5) menghasilkan RMSE yang sedikit lebih kecil. Hasil ini menunjukkan bahwa suku bilinear berperan terutama ketika anomali SST bernilai besar, sesuai dengan koefisien efektif $c_1 + b_{11} Y_{t-1}$

yang bergantung pada nilai anomali bulan sebelumnya.



Gambar 8. Data aktual (hitam) dan hasil peramalan satu langkah ke depan secara bergulir model BL(2,2,1,1) (biru) pada data uji.

3.8 Peramalan Juli sampai Desember 2026

Peramalan dilakukan setelah komponen musiman dan model BL(2,2,1,1) diduga ulang menggunakan seluruh 918 pengamatan. Model hasil pendugaan ulang konvergen dan invertibel dengan koefisien yang mendekati hasil pendugaan pada data latih. Koefisien b_{11} berubah dari 0,219 menjadi 0,204, sedangkan c_1 berubah dari $-0{,}352$ menjadi $-0{,}353$. Uji normalitas residual tidak menolak H_0 dengan nilai-p sebesar 0,210 sehingga simulasi menggunakan galat berdistribusi normal dengan 20.000 lintasan. Uji Ljung-Box kembali menolak H_0 dengan nilai-$p < 0{,}001$.

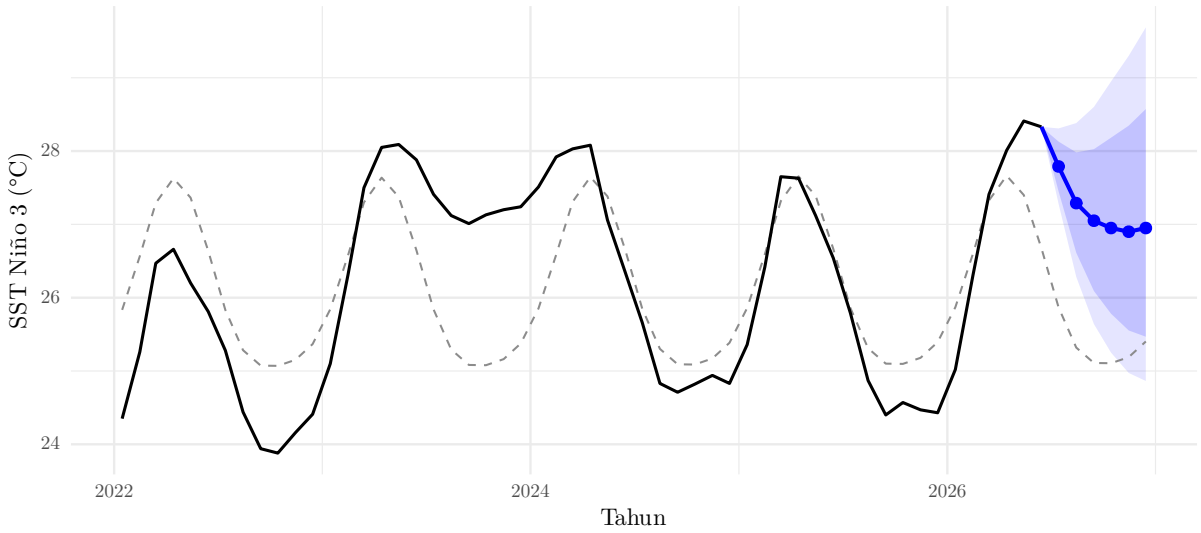
Tabel 7. Hasil peramalan SST wilayah Niño 3 Juli sampai Desember 2026 (°C).

Bulan	Komponen musiman	Anomali $\hat{Y}$	Ramalan SST	Selang 95%	Peramalan naif	ARMA(2,2)
Juli	25,87	1,92	**27,79**	27,28 sampai 28,31	27,79	27,65
Agustus	25,32	1,97	**27,29**	26,28 sampai 28,38	27,27	27,02
September	25,11	1,94	**27,05**	25,64 sampai 28,60	27,01	26,69
Oktober	25,11	1,85	**26,95**	25,25 sampai 28,95	26,88	26,56
November	25,19	1,71	**26,90**	24,97 sampai 29,30	26,79	26,49
Desember	25,40	1,55	**26,95**	24,86 sampai 29,69	26,81	26,54

Hasil peramalan disajikan pada Tabel 7 dan Gambar 9. Pada Juni 2026, SST tercatat sebesar 28,33 °C dengan Y_t sebesar 1,66 °C. Ramalan anomali meningkat menjadi 1,92 °C pada Juli dan 1,97 °C pada Agustus, kemudian menurun hingga 1,55 °C pada Desember. Seiring dengan penurunan komponen musiman, ramalan SST menurun dari 27,79 °C pada Juli menjadi 26,90 °C pada November dan 26,95 °C pada Desember. Hasil ini menunjukkan bahwa kondisi hangat diperkirakan bertahan hingga akhir 2026 dengan intensitas yang melemah.

Selang peramalan melebar seiring bertambahnya horizon. Selang peramalan 95% untuk Desember adalah 24,86 sampai 29,69 °C dan lebih lebar ke arah atas, sesuai dengan sifat asimetris model bilinear. Hasil peramalan Monte Carlo lebih tinggi 0,00 sampai 0,14 °C daripada pera-

malan naif karena peramalan naif mengabaikan nilai harapan suku $b_{11}Y_{t-1}e_{t-1}$ yang bernilai positif. Model ARMA(2,2) menghasilkan ramalan yang menurun lebih cepat, yaitu 26,54 °C pada Desember, sedangkan model BL(2,2,1,1) mempertahankan anomali positif lebih lama. Mengingat ketepatan peramalan menurun seiring bertambahnya horizon, hasil peramalan untuk bulan-bulan terakhir perlu ditafsirkan bersama selang peramalannya.



Gambar 9. SST aktual wilayah Niño 3 sejak 2022 (hitam), komponen musiman (abu-abu putus-putus), dan hasil peramalan Juli sampai Desember 2026 (biru) dengan selang peramalan 80% dan 95%.

4 Kesimpulan dan Saran

4.1 Kesimpulan

Pola musiman SST bulanan wilayah Niño 3 dapat direpresentasikan oleh dua harmonik Fourier dan tren linear sebesar 0,09 °C per dekade, sedangkan komponen stokastiknya bersifat stasioner dan nonlinear berdasarkan uji Lagrange multiplier. Dari 832 model yang dievaluasi, model BL(2,2,1,1) terpilih sebagai model dengan RMSE titik asal bergulir terkecil. Penambahan orde MA di atas dua tidak meningkatkan ketepatan peramalan, dan nilai AIC terkecil tidak menunjuk model dengan ketepatan peramalan terbaik. Pada data uji, RMSE peramalan satu langkah ke depan model BL(2,2,1,1) sebesar 0,258 °C, lebih kecil daripada model ARMA(2,2), metode persistensi, dan metode klimatologi, serta setara dengan model AR(5). Pada bulan El Niño, model BL(2,2,1,1) menghasilkan RMSE terkecil di antara seluruh model pembanding. Hasil peramalan menggunakan seluruh data menunjukkan anomali positif yang mencapai puncak 1,97 °C pada Agustus 2026 lalu melemah menjadi 1,55 °C pada Desember 2026.

4.2 Saran

Penelitian selanjutnya disarankan untuk menghitung galat baku koefisien bilinear menggunakan metode bootstrap.

Daftar Pustaka

Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723.

Bera, A. K. dan Higgins, M. L. (1993). *ARCH and Bilinearity as Competing Models for Nonlinear Dependence*. BEBR Faculty Working Paper 93-0116, University of Illinois at Urbana-Champaign.

Brown, B. W. dan Mariano, R. S. (1989). Predictors in dynamic nonlinear models: Large-sample behavior. *Econometric Theory*, 5(3), 430-452.

Burgers, G. dan Stephenson, D. B. (1999). The "normality" of El Niño. *Geophysical Research Letters*, 26, 1027-1030.

Chen, C. W. S., Cherng, T. H., dan Wu, B. (2001). On the selection of subset bilinear time series models: A genetic algorithm approach. *Computational Statistics*, 16(4), 505-517.

De Livera, A. M., Hyndman, R. J., dan Snyder, R. D. (2011). Forecasting time series with complex seasonal patterns using exponential smoothing. *Journal of the American Statistical Association*, 106(496), 1513-1527.

Dickey, D. A. dan Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74, 427-431.

Gabr, M. M. dan Subba Rao, T. (1981). The estimation and prediction of subset bilinear time series models with applications. *Journal of Time Series Analysis*, 2(3), 155-171.

Granger, C. W. J. dan Andersen, A. P. (1978a). *An Introduction to Bilinear Time Series Models*. Vandenhoeck & Ruprecht, Göttingen.

Granger, C. W. J. dan Andersen, A. P. (1978b). On the invertibility of time series models. *Stochastic Processes and their Applications*, 8(1), 87-92.

Huang, B., Thorne, P. W., Banzon, V. F., Boyer, T., Chepurin, G., Lawrimore, J. H., Menne, M. J., Smith, T. M., Vose, R. S., dan Zhang, H.-M. (2017). Extended Reconstructed Sea Surface Temperature, version 5 (ERSSTv5): Upgrades, validations, and intercomparisons. *Journal of Climate*, 30(20), 8179-8205.

Kim, W. K. (1992). Autocorrelation function structure of bilinear time series models. *Journal of the Korean Statistical Society*, 21(1), 47-58.

Kumar, K. (1986). On the identification of some bilinear time series models. *Journal of Time Series Analysis*, 7(2), 117-122.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., dan Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1-3), 159-178.

Li, W. K. (1984). On the autocorrelation structure and identification of some bilinear time series. *Journal of Time Series Analysis*, 5(3), 173-181.

Ljung, G. M. dan Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65, 297-303.

Lomnicki, Z. (1961). Tests for departure from normality in the case of linear stochastic processes. *Metrika*, 4(1), 37-62.

McLeod, A. I. dan Li, W. K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4, 269-273.

Said, S. E. dan Dickey, D. A. (1984). Testing for unit roots in autoregressive-moving average models of unknown order. *Biometrika*, 71, 599-607.

Saikkonen, P. dan Luukkonen, R. (1988). Lagrange multiplier tests for testing non-linearities in time series models. *Scandinavian Journal of Statistics*, 15, 55-68.

Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461-464.

Subba Rao, T. (1981). On the theory of bilinear time series models. *Journal of the Royal Statistical Society, Series B*, 43(2), 244-255.

Subba Rao, T. dan Gabr, M. M. (1984). *An Introduction to Bispectral Analysis and Bilinear Time Series Models*. Lecture Notes in Statistics 24. Springer, New York.

Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437-450.

Teräsvirta, T. (1994). Testing linearity and modelling nonlinear time series. *Kybernetika*, 30(3), 319-330.

Timmermann, A., dkk. (2018). El Niño Southern Oscillation complexity. *Nature*, 559, 535-545.

Trenberth, K. E. (1997). The definition of El Niño. *Bulletin of the American Meteorological Society*, 78(12), 2771-2777.

Wu, B. dan Shih, N.-H. (1992). On the identification problem for bilinear time series models. *Journal of Statistical Computation and Simulation*, 43(3-4), 129-161.