Pendugaan Parameter Model Deret Waktu Bilinear

Penurunan rumus langkah demi langkah, algoritma, dan verifikasi numerik

Zaki Abiyu Aqilah

18 Oktober 2026

Abstract

Dokumen ini menjelaskan cara menduga parameter model deret waktu bilinear dengan metode *maximum likelihood* bersyarat (*conditional maximum likelihood*), yang ternyata sama dengan meminimumkan jumlah kuadrat galat. Semua rumus diturunkan langkah demi langkah: fungsi log-likelihood, turunan galat yang bersifat rekursif, gradien dan matriks Hessian, iterasi Newton–Raphson (Gauss–Newton), galat baku, kriteria AIC, syarat invertibilitas, uji residual, dan peramalan. Dokumen ini ditulis agar dapat dibaca sendiri: setiap konsep yang dipakai dijelaskan di dalamnya. Pada bagian akhir, metode ini diuji dengan menghitung ulang tiga model data nyata yang dilaporkan Subba Rao & Gabr (1984); hasil hitung ulang cocok dengan angka yang mereka laporkan.

Contents

1 Pendahuluan **4**

2 Model dan notasi **4**

2.1 Model bilinear umum 4

2.2 Model bilinear subset 4

2.3 Konvensi 5

2.4 Stasioneritas dan invertibilitas (definisi singkat) 5

3 Fungsi likelihood dan fungsi tujuan **5**

3.1 Masalah: galat tidak teramati 5

3.2 Nilai awal 6

3.3 Densitas bersama ditulis sebagai hasil kali densitas bersyarat 6

3.4 Densitas bersyarat setiap pengamatan 6

3.5 Log-likelihood 7

3.6 Menduga σ^2 dan mereduksi masalah ke minimisasi Q 7

4 Turunan pertama galat **8**

4.1 Mengapa turunannya rekursif: contoh kecil 8

4.2 Penurunan umum 8

4.3 Tiga kasus secara eksplisit . . . 9
4.4 Nilai awal turunan . . . 9
4.5 Perluasan dengan suku MA . . . 9

5 Gradien dan matriks Hessian **11**
5.1 Konsep dasar dengan satu parameter . . . 11
5.2 Banyak parameter: vektor gradien dan matriks Hessian . . . 12
5.3 Contoh: regresi linear dan persamaan normal . . . 12
5.4 Gradien untuk model bilinear . . . 13
5.5 Hessian untuk model bilinear . . . 13
5.6 Contoh numerik . . . 14

6 Iterasi Newton–Raphson dan Gauss–Newton **14**
6.1 Mengapa perlu iterasi . . . 14
6.2 Deret Taylor: mendekati fungsi dengan polinomial . . . 15
6.3 Metode Newton–Raphson dengan satu parameter . . . 15
6.4 Newton–Raphson dengan banyak parameter . . . 16
6.5 Metode Gauss–Newton . . . 16
6.6 Kontrol ukuran langkah (*step-size control*) . . . 17
6.7 Kriteria berhenti (*stopping rule*) . . . 17
6.8 Algoritma . . . 18

7 Nilai awal **18**
7.1 Dari model autoregresif . . . 18
7.2 Metode residual berulang . . . 19
7.3 Nilai awal bertahap . . . 19
7.4 Banyak titik awal (multi-start) . . . 19

8 Pemilihan model **19**
8.1 Kriteria informasi Akaike . . . 19
8.2 Prosedur pemilihan bertahap . . . 20

9 Galat baku (*standard error*) **21**
9.1 Penurunan . . . 21
9.2 Uji signifikansi parameter . . . 21

10 Invertibilitas **22**
10.1 Mengapa penting . . . 22
10.2 Persamaan perambatan kesalahan nilai awal . . . 23

10.3 Kasus satu suku bilinear 23
10.4 Diagnostik praktis 23

11 Uji residual **23**
11.1 Uji independensi W 24
11.2 Uji normalitas (Lomnicki) 25
11.3 Tindak lanjut jika uji tidak terpenuhi 26

12 Peramalan **27**
12.1 Satu langkah ke depan 27
12.2 Dua langkah atau lebih: penurunan pada contoh 27
12.3 Aturan umum 27
12.4 Alternatif Monte Carlo 28

13 Contoh hitungan tangan **28**
13.1 Rekursi galat 29
13.2 Turunan rekursif 29
13.3 Satu langkah iterasi 30

14 Contoh iterasi manual Gauss–Newton **30**
14.1 Data dan model 30
14.2 Langkah 0: nilai awal 30
14.3 Iterasi pertama ($s = 0$) 31
14.4 Iterasi kedua ($s = 1$) 32
14.5 Iterasi berikutnya dan konvergensi 33

15 Studi simulasi **33**

16 Verifikasi dengan data nyata **33**
16.1 Model S: sunspot 34
16.2 Model L1: logaritma lynx 34
16.3 Model L2: lynx asli 35
16.4 Yang belum diverifikasi 35

17 Catatan atas angka yang tercetak di buku **35**

18 Jebakan numerik dan rekomendasi **35**

Daftar Pustaka **37**

1 Pendahuluan

Model bilinear adalah perluasan model ARMA yang memuat suku perkalian antara nilai deret di masa lalu dan galat di masa lalu. Kesulitan utama dalam pendugaan parameternya adalah bahwa galat e_t *tidak teramati*: galat harus direkonstruksi dari data, dan rekonstruksi ini sendiri bergantung pada parameter yang sedang diduga. Akibatnya, fungsi yang diminimumkan tidak berbentuk kuadratik, turunannya harus dihitung secara rekursif, dan pendugaan harus dilakukan secara iteratif.

Dokumen ini menyusun seluruh perhitungan yang diperlukan sehingga dapat dijadikan dasar untuk menulis fungsi pendugaan sendiri. Metode yang dijelaskan adalah metode yang dipakai Subba Rao & Gabr (1984). Data dan angka hasil yang dipakai sebagai pembanding juga berasal dari buku tersebut, tetapi semua hal yang diperlukan untuk memahami perhitungannya ditulis ulang di sini.

Susunan dokumen: Bagian 2 mendefinisikan model; Bagian 3 menurunkan fungsi likelihood; Bagian 4–6 menurunkan turunan dan iterasi; Bagian 7–12 membahas nilai awal, pemilihan model, galat baku, invertibilitas, uji residual, dan peramalan; Bagian 13–16 berisi contoh hitungan tangan, simulasi, dan verifikasi dengan data nyata.

2 Model dan notasi

2.1 Model bilinear umum

Definisi 2.1 (Model bilinear BL(p, r, m, k))**.** Deret waktu $\{X_t\}$ mengikuti model bilinear jika

$$X_t + \sum_{j=1}^{p} a_j X_{t-j} \;=\; \alpha + \sum_{j=1}^{r} c_j e_{t-j} + \sum_{i=1}^{m}\sum_{j=1}^{k} b_{ij}\, X_{t-i}\, e_{t-j} + e_t, \tag{1}$$

dengan $\{e_t\}$ barisan variabel acak saling bebas berdistribusi identik $N(0, \sigma^2)$.

Model ini terdiri atas empat bagian: bagian autoregresif (a_j), konstanta (α), bagian rata-rata bergerak (c_j), dan bagian bilinear (b_{ij}). Jika semua $b_{ij} = 0$, model kembali menjadi ARMA(p, r).

2.2 Model bilinear subset

Dalam praktik, sering hanya sebagian kecil koefisien yang benar-benar diperlukan. Model *subset* hanya memakai lag-lag tertentu.

Definisi 2.2 (Model bilinear subset, SBL)**.** Misalkan $\mathcal{K} = \{k_1, \ldots, k_\ell\}$ himpunan lag autoregresif dan $\mathcal{B} = \{(r_1, s_1), \ldots, (r_m, s_m)\}$ himpunan pasangan lag bilinear. Model bilinear subset adalah

$$X_t + \sum_{k \in \mathcal{K}} a_k X_{t-k} \;=\; \alpha + \sum_{(i,j) \in \mathcal{B}} b_{ij}\, X_{t-i}\, e_{t-j} + e_t. \tag{2}$$

Vektor parameternya

$$\boldsymbol{\theta} = (a_{k_1}, \ldots, a_{k_\ell},\; b_{r_1 s_1}, \ldots, b_{r_m s_m},\; \alpha)',$$

berdimensi $q = \ell + m + 1$. Selain $\boldsymbol{\theta}$, ada parameter varians σ^2.

Sebagian besar dokumen ini memakai model subset (2), karena model penuh (1) tanpa suku MA adalah kasus khususnya (ambil $\mathcal{K} = \{1, \ldots, p\}$ dan $\mathcal{B}$ berisi semua pasangan). Perluasan untuk suku MA dibahas tersendiri di Bagian 4.5.

2.3 Konvensi

Konvensi yang dipakai di seluruh dokumen

1. Koefisien autoregresif ditulis di **ruas kiri**. Model "$X_t = 0.4X_{t-1} + \ldots$" berarti $a_1 = -0.4$.
2. Pada b_{ij}, indeks pertama adalah lag X dan indeks kedua lag e: b_{ij} adalah koefisien $X_{t-i}\, e_{t-j}$. Agar suku $X_{t-i}e_{t-j}$ hanya memuat masa lalu, selalu $i \geq 1$ dan $j \geq 1$.
3. Model dipasang pada **data asli** (tidak dikurangi rata-rata) dengan konstanta α.
4. γ menyatakan lag terbesar yang dipakai, baik pada X maupun pada e.

Literatur lain kadang memakai konvensi tanda berbeda, misalnya $x_t = c + \sum \phi_i x_{t-i} + \sum\sum \beta_{ij} x_{t-i} e_{t-j} + e_t$. Hubungannya: $\phi_i = -a_i$, $c = \alpha$, $\beta_{ij} = b_{ij}$.

2.4 Stasioneritas dan invertibilitas (definisi singkat)

Stasioneritas. Model harus menghasilkan deret yang stasioner (sifat statistiknya tidak berubah terhadap waktu). Untuk kasus khusus BL$(p, 0, p, 1)$, yaitu model (1) dengan $r = 0$, $m = p$, $k = 1$, didefinisikan matriks $p \times p$

$$\mathbf{A} = \begin{pmatrix} -a_1 & -a_2 & \cdots & -a_{p-1} & -a_p \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & & \ddots & & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{pmatrix}, \qquad \mathbf{B} = \begin{pmatrix} b_{11} & b_{21} & \cdots & b_{p1} \\ 0 & 0 & \cdots & 0 \\ \vdots & & & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Subba Rao (1981) menunjukkan bahwa model ini stasioner sampai orde dua jika

$$\rho(\mathbf{A}) < 1 \quad \text{dan} \quad \rho(\mathbf{A} \otimes \mathbf{A} + \sigma^2\, \mathbf{B} \otimes \mathbf{B}) < 1,$$

dengan $\rho(\cdot)$ jari-jari spektral (nilai mutlak terbesar dari nilai eigen) dan $\otimes$ hasil kali Kronecker ($\mathbf{A} \otimes \mathbf{B}$ adalah matriks blok yang blok ke-(i,j)-nya $a_{ij}\mathbf{B}$). Untuk model subset yang lebih umum, syarat stasioneritasnya lebih rumit dan tidak dibahas di sini. Syarat ini dipakai untuk *memeriksa* hasil dugaan, bukan untuk menghitungnya.

Invertibilitas. Model disebut invertibel jika galat e_t dapat direkonstruksi dari data masa lalu dengan galat rekonstruksi yang makin kecil seiring waktu. Sifat ini sangat penting untuk pendugaan dan dibahas rinci di Bagian 10.

3 Fungsi likelihood dan fungsi tujuan

3.1 Masalah: galat tidak teramati

Data yang tersedia adalah $X_1, \ldots, X_N$. Galat e_t tidak teramati. Namun persamaan (2) dapat disusun ulang sehingga e_t berada di ruas kiri:

$$\boxed{e_t = X_t + \sum_{k \in \mathcal{K}} a_k X_{t-k} - \alpha - \sum_{(i,j) \in \mathcal{B}} b_{ij}\, X_{t-i}\, e_{t-j}.} \tag{3}$$

Ruas kanan memuat e_{t-j} dengan $j \geq 1$, yaitu galat *sebelumnya*. Jadi jika galat sebelumnya sudah diketahui, e_t dapat dihitung. Ini memberi cara menghitung galat satu per satu secara berurutan (rekursif).

3.2 Nilai awal

Rekursi (3) memerlukan titik mulai. Lag terbesar adalah γ, sehingga untuk menghitung e_t diperlukan $X_{t-1}, \ldots, X_{t-\gamma}$ dan $e_{t-1}, \ldots, e_{t-\gamma}$. Kita:

1. memperlakukan $X_1, \ldots, X_\gamma$ sebagai nilai awal yang tetap (dikondisikan);
2. menetapkan
$$e_1 = e_2 = \cdots = e_\gamma = 0, \tag{4}$$
karena nilainya tidak diketahui dan ekspektasinya nol;
3. menghitung $e_{\gamma+1}, e_{\gamma+2}, \ldots, e_N$ dengan (3) secara berurutan.

Banyaknya galat yang dihitung adalah

$$n = N - \gamma.$$

Penetapan (4) adalah pendekatan. Pendekatan ini baik hanya jika pengaruh nilai awal yang salah menghilang seiring waktu, yaitu jika model invertibel (Bagian 10).

Karena e_t yang dihitung bergantung pada nilai parameter, kita menuliskannya $e_t(\boldsymbol{\theta})$.

3.3 Densitas bersama ditulis sebagai hasil kali densitas bersyarat

Misalkan $\mathcal{F}_{t-1}$ menyatakan informasi sampai waktu $t-1$, yaitu $X_1, \ldots, X_{t-1}$. Dengan aturan perkalian peluang, densitas bersama $X_{\gamma+1}, \ldots, X_N$ (bersyarat pada $X_1, \ldots, X_\gamma$) dapat ditulis

$$f(X_{\gamma+1}, \ldots, X_N \mid X_1, \ldots, X_\gamma) = \prod_{t=\gamma+1}^{N} f(X_t \mid \mathcal{F}_{t-1}). \tag{5}$$

Ini hanya penerapan berulang dari $f(u, v) = f(v \mid u)\, f(u)$: densitas bersama sama dengan densitas $X_{\gamma+1}$ diberi masa lalu, dikali densitas $X_{\gamma+2}$ diberi masa lalunya, dan seterusnya.

3.4 Densitas bersyarat setiap pengamatan

Tulis (2) sebagai

$$X_t = \mu_t + e_t, \qquad \mu_t = -\sum_{k \in \mathcal{K}} a_k X_{t-k} + \alpha + \sum_{(i,j) \in \mathcal{B}} b_{ij} X_{t-i} e_{t-j}.$$

Semua komponen μ_t diketahui jika $\mathcal{F}_{t-1}$ diketahui: X_{t-k} dan X_{t-i} adalah data lampau, dan e_{t-j} dihitung dari data lampau dengan rekursi (3). Jadi, *diberi* $\mathcal{F}_{t-1}$, nilai μ_t adalah konstanta. Sementara itu e_t bebas dari masa lalu dan berdistribusi $N(0, \sigma^2)$. Karena X_t adalah konstanta μ_t ditambah variabel normal e_t,

$$X_t \mid \mathcal{F}_{t-1} \;\sim\; N(\mu_t,\, \sigma^2),$$

sehingga

$$f(X_t \mid \mathcal{F}_{t-1}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(-\frac{(X_t - \mu_t)^2}{2\sigma^2} \Big) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(-\frac{e_t(\boldsymbol{\theta})^2}{2\sigma^2} \Big),$$

karena $X_t - \mu_t = e_t(\boldsymbol{\theta})$ menurut (3).

Catatan

Cara lain melihat langkah ini adalah *perubahan variabel*. Pemetaan dari $(e_{\gamma+1}, \ldots, e_N)$ ke $(X_{\gamma+1}, \ldots, X_N)$ bersifat segitiga: X_t hanya bergantung pada e_t dan nilai-nilai sebelumnya, dengan $\partial X_t / \partial e_t = 1$. Determinan Jacobian matriks segitiga adalah hasil kali diagonalnya, yaitu 1. Karena itu densitas X sama dengan densitas e yang dievaluasi pada $e_t(\boldsymbol{\theta})$, tanpa faktor pengali.

3.5 Log-likelihood

Substitusikan densitas bersyarat ke (5). Fungsi likelihood bersyarat adalah

$$L(\boldsymbol{\theta}, \sigma^2) = \prod_{t=\gamma+1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\!\Big(-\frac{e_t(\boldsymbol{\theta})^2}{2\sigma^2} \Big).$$

Ambil logaritma. Logaritma hasil kali adalah jumlah logaritma, dan untuk setiap faktor

$$\log\Big[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\!\Big(-\frac{e_t^2}{2\sigma^2} \Big) \Big] = -\tfrac{1}{2}\log(2\pi) - \tfrac{1}{2}\log\sigma^2 - \frac{e_t^2}{2\sigma^2}.$$

Menjumlahkan n faktor memberi

$$\boxed{\log L(\boldsymbol{\theta}, \sigma^2) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log\sigma^2 - \frac{Q(\boldsymbol{\theta})}{2\sigma^2}, \qquad Q(\boldsymbol{\theta}) = \sum_{t=\gamma+1}^{N} e_t(\boldsymbol{\theta})^2.} \tag{6}$$

3.6 Menduga σ^2 dan mereduksi masalah ke minimisasi Q

Untuk $\boldsymbol{\theta}$ tetap, maksimumkan (6) terhadap σ^2. Turunannya:

$$\frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{Q(\boldsymbol{\theta})}{2\sigma^4}.$$

Samakan dengan nol: $-n\sigma^2 + Q(\boldsymbol{\theta}) = 0$, sehingga

$$\hat{\sigma}^2(\boldsymbol{\theta}) = \frac{Q(\boldsymbol{\theta})}{n}. \tag{7}$$

Substitusikan kembali ke (6). Suku terakhir menjadi $Q/(2Q/n) = n/2$, sehingga

$$\log L(\boldsymbol{\theta}, \hat{\sigma}^2(\boldsymbol{\theta})) = -\frac{n}{2}\big(1 + \log 2\pi\big) - \frac{n}{2}\log\frac{Q(\boldsymbol{\theta})}{n}. \tag{8}$$

Fungsi (8) disebut *profile log-likelihood*. Fungsi log naik monoton, dan $-\frac{n}{2}\log(\cdot)$ turun monoton. Jadi memaksimumkan (8) terhadap $\boldsymbol{\theta}$ sama dengan meminimumkan $Q(\boldsymbol{\theta})$:

$$\boxed{\hat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}), \qquad \hat{\sigma}^2 = Q(\hat{\boldsymbol{\theta}})/n.}$$

Metode ini disebut *conditional least squares* (CLS); di bawah asumsi normal ia identik dengan *conditional maximum likelihood estimation* (MLE bersyarat).

Catatan

Nilai $n = N - \gamma$ harus *sama* untuk semua model yang dibandingkan, sebab kriteria seperti AIC (Bagian 8) hanya bermakna jika dihitung pada pengamatan yang sama. Karena itu γ ditetapkan sekali di awal sebagai lag terbesar yang mungkin dipakai oleh model mana pun yang akan dibandingkan.

4 Turunan pertama galat

Untuk meminimumkan $Q(\boldsymbol{\theta})$ diperlukan turunannya, dan turunan Q memerlukan turunan setiap $e_t(\boldsymbol{\theta})$.

4.1 Mengapa turunannya rekursif: contoh kecil

Ambil model satu suku AR dan satu suku bilinear, $X_t + aX_{t-1} = \alpha + bX_{t-1}e_{t-1} + e_t$, dengan $\gamma = 1$. Rekursinya $e_t = X_t + aX_{t-1} - \alpha - bX_{t-1}e_{t-1}$, dan $e_1 = 0$. Maka

$$\begin{aligned} e_2 &= X_2 + aX_1 - \alpha - bX_1 \cdot 0 = X_2 + aX_1 - \alpha, \\ e_3 &= X_3 + aX_2 - \alpha - bX_2\, e_2 = X_3 + aX_2 - \alpha - bX_2\,(X_2 + aX_1 - \alpha). \end{aligned}$$

Terlihat bahwa e_3 bergantung pada b *dua kali*: secara langsung melalui $-bX_2(\cdot)$, dan secara tidak langsung melalui e_2 yang juga bergantung pada a dan α. Jika diturunkan terhadap a:

$$\frac{\partial e_3}{\partial a} = X_2 - bX_2 \frac{\partial e_2}{\partial a} = X_2 - bX_2X_1.$$

Suku $-bX_2X_1$ berasal dari ketergantungan e_2 pada a. Jika suku ini diabaikan, turunannya salah. Semakin besar t, rantai ketergantungan ini semakin panjang, karena e_t bergantung pada e_{t-1}, yang bergantung pada e_{t-2}, dan seterusnya. Untungnya rantai ini dapat ditangani secara rekursif, seperti diturunkan berikut.

4.2 Penurunan umum

Notasikan turunan galat terhadap parameter ke-u dengan

$$\psi_{t,u} = \frac{\partial e_t(\boldsymbol{\theta})}{\partial \theta_u}, \qquad u = 1, \ldots, q.$$

Turunkan kedua ruas (3) terhadap θ_u, suku demi suku:

1. $\dfrac{\partial X_t}{\partial \theta_u} = 0$, karena X_t adalah data, bukan fungsi parameter.
2. Untuk suku AR, X_{t-k} juga data, sehingga $\dfrac{\partial}{\partial \theta_u}\big(a_k X_{t-k}\big) = X_{t-k}\dfrac{\partial a_k}{\partial \theta_u}$, yang bernilai X_{t-k} jika $\theta_u = a_k$ dan 0 jika bukan.
3. $\dfrac{\partial \alpha}{\partial \theta_u}$ bernilai 1 jika $\theta_u = \alpha$ dan 0 jika bukan.
4. Suku bilinear $b_{ij}X_{t-i}e_{t-j}(\boldsymbol{\theta})$ adalah hasil kali dua besaran yang bergantung pada $\boldsymbol{\theta}$, yaitu b_{ij} dan $e_{t-j}(\boldsymbol{\theta})$ (X_{t-i} adalah data). Dengan aturan hasil kali $(fg)' = f'g + fg'$:

$$\frac{\partial}{\partial \theta_u}\big(b_{ij}X_{t-i}e_{t-j}\big) = \frac{\partial b_{ij}}{\partial \theta_u}\, X_{t-i}e_{t-j} + b_{ij}X_{t-i}\,\frac{\partial e_{t-j}}{\partial \theta_u} = \frac{\partial b_{ij}}{\partial \theta_u}\, X_{t-i}e_{t-j} + b_{ij}X_{t-i}\,\psi_{t-j,u}.$$

Gabungkan keempat bagian dengan tanda masing-masing dari (3):

$$\psi_{t,u} = \sum_{k\in\mathcal{K}} X_{t-k}\frac{\partial a_k}{\partial \theta_u} - \frac{\partial \alpha}{\partial \theta_u} - \sum_{(i,j)\in\mathcal{B}} \frac{\partial b_{ij}}{\partial \theta_u} X_{t-i}e_{t-j} - \sum_{(i,j)\in\mathcal{B}} b_{ij}X_{t-i}\,\psi_{t-j,u}.$$

Tiga jumlah pertama hanya menyisakan satu suku (suku untuk parameter θ_u itu sendiri); sebut sebagai *suku langsung* $d_{t,u}$. Jumlah terakhir adalah *suku rekursif*. Jadi

$$\psi_{t,u} = d_{t,u} - \sum_{(i,j)\in\mathcal{B}} b_{ij}\, X_{t-i}\, \psi_{t-j,u}, \qquad d_{t,u} = \begin{cases} X_{t-k} & \text{jika } \theta_u = a_k, \\ -X_{t-r}\, e_{t-s} & \text{jika } \theta_u = b_{rs}, \\ -1 & \text{jika } \theta_u = \alpha. \end{cases} \tag{9}$$

4.3 Tiga kasus secara eksplisit

Menuliskan (9) untuk setiap jenis parameter memberi:

$$\boxed{\begin{aligned} \frac{\partial e_t}{\partial a_k} &= X_{t-k} - \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial a_k}, \\ \frac{\partial e_t}{\partial b_{rs}} &= -X_{t-r} e_{t-s} - \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial b_{rs}}, \\ \frac{\partial e_t}{\partial \alpha} &= -1 - \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial \alpha}. \end{aligned}} \tag{10}$$

Perhatikan bahwa suku rekursifnya sama untuk ketiga jenis parameter; yang berbeda hanya suku langsungnya.

4.4 Nilai awal turunan

Karena $e_t = 0$ untuk $t \le \gamma$ adalah konstanta yang tidak bergantung pada $\boldsymbol{\theta}$, turunannya juga nol:

$$\psi_{t,u} = 0, \qquad t \le \gamma,\ u = 1, \ldots, q.$$

Dengan demikian, untuk setiap $t = \gamma + 1, \ldots, N$, kita hitung e_t dengan (3) lalu $\psi_{t,u}$ dengan (10), memakai e dan ψ yang sudah dihitung pada waktu sebelumnya. Keduanya dapat dihitung dalam satu putaran yang sama.

Kebenaran rumus ini dapat diperiksa secara numerik dengan beda hingga, $\psi_{t,u} \approx \big[e_t(\boldsymbol{\theta} + h\mathbf{1}_u) - e_t(\boldsymbol{\theta} - h\mathbf{1}_u)\big]/(2h)$ untuk h kecil (Bagian 13).

4.5 Perluasan dengan suku MA

Bagian ini menurunkan ulang rekursi galat dan turunannya ketika model juga memuat bagian rata-rata bergerak (MA).

Langkah 1: model. Misalkan $\mathcal{C}$ himpunan lag MA. Model subset dengan suku MA adalah

$$X_t + \sum_{k\in\mathcal{K}} a_k X_{t-k} = \alpha + \sum_{l\in\mathcal{C}} c_l\, e_{t-l} + \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} e_{t-j} + e_t,$$

dan vektor parameternya bertambah dengan koefisien c_l, $l \in \mathcal{C}$.

Langkah 2: rekursi galat. Pindahkan semua suku kecuali e_t ke ruas kiri:

$$e_t = X_t + \sum_{k\in\mathcal{K}} a_k X_{t-k} - \alpha - \sum_{l\in\mathcal{C}} c_l\, e_{t-l} - \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} e_{t-j}. \tag{11}$$

Sekarang galat masa lalu muncul di *dua* tempat: pada suku MA dan pada suku bilinear. Nilai awalnya tetap $e_t = 0$ untuk $t \le \gamma$, dengan γ kini juga mencakup lag MA terbesar.

Langkah 3: turunkan suku demi suku. Turunkan (11) terhadap θ_u. Empat jenis suku diperlakukan seperti sebelumnya (X_t data; suku AR; konstanta; suku bilinear dengan aturan hasil kali). Suku MA $c_l\, e_{t-l}(\boldsymbol{\theta})$ juga merupakan hasil kali dua besaran yang bergantung pada $\boldsymbol{\theta}$, yaitu c_l dan $e_{t-l}(\boldsymbol{\theta})$, sehingga dengan aturan hasil kali

$$\frac{\partial}{\partial\theta_u}\big(c_l\, e_{t-l}\big) = \frac{\partial c_l}{\partial\theta_u}\, e_{t-l} + c_l\, \frac{\partial e_{t-l}}{\partial\theta_u} = \frac{\partial c_l}{\partial\theta_u}\, e_{t-l} + c_l\, \psi_{t-l,u}.$$

Suku pertama bernilai e_{t-l} hanya jika $\theta_u = c_l$, dan nol untuk parameter lain.

Langkah 4: gabungkan. Dengan tanda dari (11),

$$\psi_{t,u} = \underbrace{\sum_k X_{t-k}\frac{\partial a_k}{\partial\theta_u} - \frac{\partial\alpha}{\partial\theta_u} - \sum_l \frac{\partial c_l}{\partial\theta_u} e_{t-l} - \sum_{(i,j)} \frac{\partial b_{ij}}{\partial\theta_u} X_{t-i} e_{t-j}}_{\text{suku langsung } d_{t,u}}$$
$$- \sum_{l\in\mathcal{C}} c_l\, \psi_{t-l,u} \; - \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i}\, \psi_{t-j,u}.$$

Suku langsung hanya menyisakan satu suku untuk setiap parameter, sehingga diperoleh empat rumus:

$$\boxed{\begin{aligned}
\frac{\partial e_t}{\partial a_k} &= X_{t-k} && - \textstyle\sum_l c_l \frac{\partial e_{t-l}}{\partial a_k} - \sum_{(i,j)} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial a_k},\\
\frac{\partial e_t}{\partial c_m} &= -e_{t-m} && - \textstyle\sum_l c_l \frac{\partial e_{t-l}}{\partial c_m} - \sum_{(i,j)} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial c_m},\\
\frac{\partial e_t}{\partial b_{rs}} &= -X_{t-r} e_{t-s} && - \textstyle\sum_l c_l \frac{\partial e_{t-l}}{\partial b_{rs}} - \sum_{(i,j)} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial b_{rs}},\\
\frac{\partial e_t}{\partial \alpha} &= -1 && - \textstyle\sum_l c_l \frac{\partial e_{t-l}}{\partial \alpha} - \sum_{(i,j)} b_{ij} X_{t-i} \frac{\partial e_{t-j}}{\partial \alpha}.
\end{aligned}} \tag{12}$$

Dibandingkan dengan (10), ada dua perubahan: muncul rumus baru untuk c_m dengan suku langsung $-e_{t-m}$, dan setiap rumus mendapat suku rekursif tambahan $-\sum_l c_l\, \partial e_{t-l}/\partial\theta_u$.

Contoh. Ambil satu suku AR, satu suku MA, dan satu suku bilinear pada lag 1:

$$X_t + aX_{t-1} = \alpha + c\, e_{t-1} + b\, X_{t-1} e_{t-1} + e_t.$$

Rekursi galatnya dapat ditulis ringkas karena suku MA dan suku bilinear sama-sama memuat e_{t-1}:

$$e_t = X_t + aX_{t-1} - \alpha - (c + bX_{t-1})\, e_{t-1}.$$

Turunannya mengikuti (12), dengan pengali rekursif yang sama ($c+bX_{t-1}$) untuk semua parameter:

$$\frac{\partial e_t}{\partial a} = X_{t-1} - (c + bX_{t-1})\frac{\partial e_{t-1}}{\partial a}, \qquad \frac{\partial e_t}{\partial c} = -e_{t-1} - (c + bX_{t-1})\frac{\partial e_{t-1}}{\partial c},$$

$$\frac{\partial e_t}{\partial b} = -X_{t-1}e_{t-1} - (c + bX_{t-1})\frac{\partial e_{t-1}}{\partial b}, \qquad \frac{\partial e_t}{\partial \alpha} = -1 - (c + bX_{t-1})\frac{\partial e_{t-1}}{\partial \alpha}.$$

Dengan data $X = (1.2,\ 0.8,\ 1.9,\ 0.4,\ 1.5,\ 1.1)$ dan $(a, c, b, \alpha) = (-0.4,\ 0.2,\ 0.3,\ 0.5)$, misalnya untuk turunan terhadap c:

$$\begin{aligned} e_2 &= 0.8 + (-0.4)(1.2) - 0.5 - (0.2 + 0.3 \cdot 1.2)(0) = -0.1800, \\ e_3 &= 1.9 + (-0.4)(0.8) - 0.5 - (0.2 + 0.3 \cdot 0.8)(-0.18) = 1.1592, \\ e_4 &= 0.4 + (-0.4)(1.9) - 0.5 - (0.2 + 0.3 \cdot 1.9)(1.1592) = -1.7526, \end{aligned}$$

dan

$$\begin{aligned} \tfrac{\partial e_2}{\partial c} &= -e_1 - (0.2 + 0.3 \cdot 1.2)(0) = 0, \\ \tfrac{\partial e_3}{\partial c} &= -e_2 - (0.2 + 0.3 \cdot 0.8)\tfrac{\partial e_2}{\partial c} = 0.18 - (0.44)(0) = 0.1800, \\ \tfrac{\partial e_4}{\partial c} &= -e_3 - (0.2 + 0.3 \cdot 1.9)\tfrac{\partial e_3}{\partial c} = -1.1592 - (0.77)(0.18) = -1.2978. \end{aligned}$$

Melanjutkan sampai $t = 6$ memberi $\partial e_6/\partial(a, c, b, \alpha) = (1.5916,\ -2.8099,\ -3.0381,\ -0.4683)$; nilai beda hingga dengan pergeseran $\pm 10^{-6}$ identik sampai enam desimal.

Hubungan dengan model yang sudah dikenal. Jika $a = 0$ dan $b = 0$, model menjadi MA(1) dan rekursinya $e_t = X_t - \alpha - c\, e_{t-1}$, yaitu rekursi yang dipakai pada pendugaan *conditional sum of squares* untuk model ARIMA. Pengali rekursif $(c + bX_{t-1})$ juga menentukan invertibilitas: dengan argumen Bagian 10, syaratnya $\mathbb{E} \log |c + bX_t| < 0$, yang untuk $b = 0$ menjadi syarat invertibilitas MA(1) yang klasik, $|c| < 1$.

5 Gradien dan matriks Hessian

Bagian ini dimulai dari konsep dasarnya, karena keduanya adalah alat utama untuk mencari nilai parameter yang meminimumkan $Q(\boldsymbol{\theta})$.

5.1 Konsep dasar dengan satu parameter

Misalkan kita ingin meminimumkan fungsi $Q(\theta)$ dengan satu parameter.

- **Turunan pertama** $Q'(\theta)$ adalah kemiringan (slope) kurva Q di titik θ. Jika $Q'(\theta) > 0$, Q naik bila θ diperbesar; jika $Q'(\theta) < 0$, Q turun bila θ diperbesar. Di titik minimum kurvanya datar, sehingga
$$Q'(\hat{\theta}) = 0 \qquad \text{(syarat orde pertama)}.$$
- **Turunan kedua** $Q''(\theta)$ adalah kelengkungan kurva, yaitu seberapa cepat kemiringannya berubah. Titik dengan $Q' = 0$ adalah minimum jika kurvanya melengkung ke atas:
$$Q''(\hat{\theta}) > 0 \qquad \text{(syarat orde kedua)}.$$

Contoh yang sudah dikenal: rata-rata sampel. Untuk data $y_1, \ldots, y_n$, ambil $Q(\theta) = \sum_t (y_t - \theta)^2$. Maka

$$Q'(\theta) = \sum_t 2(y_t - \theta)(-1) = -2\sum_t (y_t - \theta), \qquad Q''(\theta) = 2n.$$

Syarat $Q'(\hat{\theta}) = 0$ memberi $\sum_t y_t - n\hat{\theta} = 0$, yaitu $\hat{\theta} = \bar{y}$; karena $Q'' = 2n > 0$, titik ini memang minimum. Jadi rata-rata sampel adalah penduga kuadrat terkecil bagi θ.

5.2 Banyak parameter: vektor gradien dan matriks Hessian

Jika ada q parameter $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_q)'$, peran turunan pertama dan kedua digantikan oleh:

- **Vektor gradien**, yaitu vektor $q \times 1$ berisi turunan parsial pertama:

$$\mathbf{g}(\boldsymbol{\theta}) = \frac{\partial Q}{\partial \boldsymbol{\theta}} = \begin{pmatrix} \partial Q/\partial \theta_1 \\ \vdots \\ \partial Q/\partial \theta_q \end{pmatrix}.$$

  Gradien menunjukkan arah kenaikan Q yang paling curam; arah $-\mathbf{g}$ adalah arah penurunan paling curam.

- **Matriks Hessian**, yaitu matriks $q \times q$ berisi semua turunan parsial kedua:

$$\mathbf{H}(\boldsymbol{\theta}) = \frac{\partial^2 Q}{\partial \boldsymbol{\theta}\, \partial \boldsymbol{\theta}'} = \begin{pmatrix} \frac{\partial^2 Q}{\partial \theta_1^2} & \frac{\partial^2 Q}{\partial \theta_1 \partial \theta_2} & \cdots & \frac{\partial^2 Q}{\partial \theta_1 \partial \theta_q} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 Q}{\partial \theta_q \partial \theta_1} & \frac{\partial^2 Q}{\partial \theta_q \partial \theta_2} & \cdots & \frac{\partial^2 Q}{\partial \theta_q^2} \end{pmatrix}.$$

  Entri ke-(u, v) menyatakan bagaimana kemiringan terhadap θ_u berubah bila θ_v berubah. Matriks ini simetris karena urutan penurunan tidak berpengaruh ($\partial^2 Q/\partial\theta_u \partial\theta_v = \partial^2 Q/\partial\theta_v \partial\theta_u$).

Syarat minimum menjadi:

$$\mathbf{g}(\hat{\boldsymbol{\theta}}) = \mathbf{0} \quad \text{(semua kemiringan nol)}, \qquad \mathbf{H}(\hat{\boldsymbol{\theta}}) \text{ definit positif},$$

dengan *definit positif* berarti $\mathbf{v}'\mathbf{H}\mathbf{v} > 0$ untuk setiap vektor $\mathbf{v} \neq \mathbf{0}$, yaitu kurva Q melengkung ke atas ke arah mana pun.

5.3 Contoh: regresi linear dan persamaan normal

Pada regresi linear $y_t = \mathbf{x}_t'\boldsymbol{\beta} + e_t$, jumlah kuadrat galatnya

$$Q(\boldsymbol{\beta}) = \sum_t (y_t - \mathbf{x}_t'\boldsymbol{\beta})^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Galat $e_t = y_t - \mathbf{x}_t'\boldsymbol{\beta}$ memiliki turunan $\partial e_t/\partial \boldsymbol{\beta} = -\mathbf{x}_t$. Gradien dan Hessiannya

$$\mathbf{g}(\boldsymbol{\beta}) = \sum_t 2e_t(-\mathbf{x}_t) = -2\mathbf{X}'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \qquad \mathbf{H} = 2\sum_t \mathbf{x}_t\mathbf{x}_t' = 2\mathbf{X}'\mathbf{X}.$$

Syarat $\mathbf{g} = \mathbf{0}$ memberi persamaan normal $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{y}$, sehingga $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, yaitu penduga OLS. Hessian $2\mathbf{X}'\mathbf{X}$ definit positif bila $\mathbf{X}$ berpangkat kolom penuh, sehingga titik ini minimum.

Pada regresi linear, gradien linear dalam $\boldsymbol{\beta}$, sehingga $\mathbf{g} = \mathbf{0}$ dapat diselesaikan langsung. Pada model bilinear, $e_t(\boldsymbol{\theta})$ *tidak* linear dalam $\boldsymbol{\theta}$ (karena e_{t-j} sendiri bergantung pada $\boldsymbol{\theta}$), sehingga $\mathbf{g}(\boldsymbol{\theta}) = \mathbf{0}$ tidak dapat diselesaikan secara langsung dan harus didekati secara iteratif (Bagian 6).

Kaitan dengan fungsi likelihood. Dalam istilah statistika, gradien log-likelihood disebut *fungsi skor*, dan negatif Hessian log-likelihood disebut *informasi Fisher teramati*. Karena $\log L =$ konstanta$-Q(\boldsymbol{\theta})/(2\sigma^2)$ menurut (6), fungsi skornya $-\mathbf{g}/(2\sigma^2)$ dan informasi teramatinya $\mathbf{H}/(2\sigma^2)$. Jadi meminimumkan Q dengan gradien dan Hessian sama dengan memaksimumkan log-likelihood dengan fungsi skor dan informasi Fisher.

5.4 Gradien untuk model bilinear

Fungsi tujuannya $Q(\boldsymbol{\theta}) = \sum_{t=\gamma+1}^{N} e_t(\boldsymbol{\theta})^2$. Turunan parsial terhadap θ_u adalah jumlah turunan setiap suku. Dengan aturan rantai, $\dfrac{\partial}{\partial\theta_u}\big[e_t(\boldsymbol{\theta})\big]^2 = 2\,e_t(\boldsymbol{\theta})\,\dfrac{\partial e_t(\boldsymbol{\theta})}{\partial\theta_u} = 2e_t\psi_{t,u}$. Jadi

$$g_u = \frac{\partial Q}{\partial\theta_u} = 2\sum_{t=\gamma+1}^{N} e_t\,\psi_{t,u}, \qquad u = 1,\ldots,q.$$

Untuk menuliskannya dalam bentuk matriks, susun galat dan turunannya:

$$\mathbf{e} = \begin{pmatrix} e_{\gamma+1} \\ e_{\gamma+2} \\ \vdots \\ e_N \end{pmatrix}_{n\times 1}, \qquad \mathbf{J} = \begin{pmatrix} \psi_{\gamma+1,1} & \psi_{\gamma+1,2} & \cdots & \psi_{\gamma+1,q} \\ \psi_{\gamma+2,1} & \psi_{\gamma+2,2} & \cdots & \psi_{\gamma+2,q} \\ \vdots & \vdots & & \vdots \\ \psi_{N,1} & \psi_{N,2} & \cdots & \psi_{N,q} \end{pmatrix}_{n\times q}.$$

Baris ke-t matriks $\mathbf{J}$ berisi turunan e_t terhadap semua parameter; kolom ke-u berisi turunan semua galat terhadap θ_u. Entri ke-u dari $\mathbf{J}'\mathbf{e}$ adalah kolom ke-u dari $\mathbf{J}$ dikali $\mathbf{e}$, yaitu $\sum_t \psi_{t,u}e_t$. Karena itu

$$\boxed{\mathbf{g} = 2\mathbf{J}'\mathbf{e}.} \tag{13}$$

Bandingkan dengan regresi linear: di sana $\psi_t = -\mathbf{x}_t$, sehingga $\mathbf{J} = -\mathbf{X}$ dan $2\mathbf{J}'\mathbf{e} = -2\mathbf{X}'\mathbf{e}$, sama dengan gradien di atas.

5.5 Hessian untuk model bilinear

Entri ke-(u,v) diperoleh dengan menurunkan $g_u = 2\sum_t e_t\psi_{t,u}$ terhadap θ_v. Setiap suku $e_t\psi_{t,u}$ adalah hasil kali dua fungsi dari $\boldsymbol{\theta}$, sehingga dengan aturan hasil kali:

$$\frac{\partial^2 Q}{\partial\theta_u\partial\theta_v} = 2\sum_t\Big(\frac{\partial e_t}{\partial\theta_v}\,\psi_{t,u} + e_t\,\frac{\partial\psi_{t,u}}{\partial\theta_v}\Big) = \underbrace{2\sum_t \psi_{t,u}\psi_{t,v}}_{\text{bagian I}} + \underbrace{2\sum_t e_t\frac{\partial^2 e_t}{\partial\theta_u\partial\theta_v}}_{\text{bagian II}}.$$

Dalam bentuk matriks, bagian I adalah $2\mathbf{J}'\mathbf{J}$ (entri ke-(u,v) dari $\mathbf{J}'\mathbf{J}$ adalah kolom u dikali kolom v, yaitu $\sum_t \psi_{t,u}\psi_{t,v}$).

Pemeriksaan pada regresi linear. Di sana e_t linear dalam $\boldsymbol{\beta}$, sehingga turunan keduanya nol dan bagian II hilang. Hessian $= 2\mathbf{J}'\mathbf{J} = 2\mathbf{X}'\mathbf{X}$, sama dengan hasil sebelumnya.

Mengapa bagian II dapat diabaikan pada model bilinear. Pada model bilinear, turunan kedua e_t tidak nol, dan menghitungnya memerlukan rekursi tambahan yang rumit. Namun pada nilai parameter yang benar, e_t adalah galat sebenarnya, yang saling bebas dengan masa lalu, sedangkan $\partial^2 e_t/\partial\theta_u\partial\theta_v$ hanya bergantung pada data masa lalu (ruas kanan (10) hanya memuat besaran pada waktu $t-1$ ke belakang). Untuk dua variabel acak yang saling bebas, ekspektasi hasil kalinya sama dengan hasil kali ekspektasinya, dan $\mathbb{E}(e_t) = 0$, sehingga

$$\mathbb{E}\Big(e_t\,\frac{\partial^2 e_t}{\partial\theta_u\partial\theta_v}\Big) = \mathbb{E}(e_t)\,\mathbb{E}\Big(\frac{\partial^2 e_t}{\partial\theta_u\partial\theta_v}\Big) = 0.$$

Menurut hukum bilangan besar, rata-rata $\frac{1}{n}\times$bagian II mendekati nol untuk n besar, sedangkan $\frac{1}{n}\times$bagian I mendekati nilai positif. Karena itu Hessian didekati dengan bagian I saja:

$$\boxed{\mathbf{H} \approx 2\mathbf{J}'\mathbf{J}.} \tag{14}$$

Pendekatan ini dipakai luas dalam kuadrat terkecil nonlinear (Marquardt, 1963).

Sifat penting. Untuk sembarang vektor $\mathbf{v}$, $\mathbf{v}'(\mathbf{J}'\mathbf{J})\mathbf{v} = (\mathbf{J}\mathbf{v})'(\mathbf{J}\mathbf{v}) = \|\mathbf{J}\mathbf{v}\|^2 \geq 0$. Jadi $2\mathbf{J}'\mathbf{J}$ selalu semi-definit positif, dan definit positif bila kolom-kolom $\mathbf{J}$ bebas linear. Akibatnya arah langkah yang dihasilkannya (Bagian 6) selalu merupakan arah penurunan Q, berbeda dengan Hessian lengkap yang bisa tidak definit positif jauh dari minimum.

5.6 Contoh numerik

Pada contoh hitungan tangan (Bagian 13), model $X_t + aX_{t-1} = \alpha + bX_{t-1}e_{t-1} + e_t$ dievaluasi pada $(a, b, \alpha) = (-0.4, 0.3, 0.5)$ dan memberi

$$\mathbf{g} = \begin{pmatrix} -4.9762 \\ 10.5021 \\ -1.0149 \end{pmatrix}, \qquad \mathbf{H} \approx 2\mathbf{J}'\mathbf{J} = \begin{pmatrix} 12.6208 & -12.0234 & -7.0208 \\ -12.0234 & 18.7351 & 2.9084 \\ -7.0208 & 2.9084 & 6.2091 \end{pmatrix}.$$

Gradien tidak nol, jadi titik ini belum minimum. Komponen untuk b bernilai positif (10.50), artinya Q akan turun bila b diperkecil; komponen untuk a negatif, artinya Q akan turun bila a diperbesar. Hessian menentukan seberapa jauh langkah yang diambil ke arah tersebut.

6 Iterasi Newton–Raphson dan Gauss–Newton

Bagian sebelumnya memberi gradien $\mathbf{g}$ dan matriks Hessian $\mathbf{H}$. Bagian ini menjelaskan bagaimana keduanya dipakai untuk *menemukan* $\hat{\boldsymbol{\theta}}$ secara numerik, mulai dari konsep dasarnya.

6.1 Mengapa perlu iterasi

Pada regresi linear, syarat $\mathbf{g}(\boldsymbol{\beta}) = \mathbf{0}$ berbentuk persamaan linear (persamaan normal), sehingga $\hat{\boldsymbol{\beta}}$ dapat dihitung langsung dengan satu rumus. Pada model bilinear, $\mathbf{g}(\boldsymbol{\theta}) = 2\mathbf{J}'\mathbf{e}$ bergantung pada $\boldsymbol{\theta}$ secara nonlinear, karena e_t dan $\psi_{t,u}$ dihitung dengan rekursi yang memuat $\boldsymbol{\theta}$. Persamaan $\mathbf{g}(\boldsymbol{\theta}) = \mathbf{0}$ tidak dapat diselesaikan dengan satu rumus. Yang dapat dilakukan adalah: mulai dari suatu tebakan, perbaiki tebakan itu sedikit demi sedikit, dan ulangi sampai tebakan tidak lagi berubah. Prosedur berulang semacam ini disebut *iterasi*.

Notasi iterasi

- $s = 0, 1, 2, \ldots$ adalah **nomor iterasi** (urutan perbaikan), *bukan* waktu. Indeks waktu tetap ditulis t.
- $\boldsymbol{\theta}^{(0)}$ adalah nilai awal (tebakan pertama), dan $\boldsymbol{\theta}^{(s)}$ adalah nilai dugaan parameter setelah s kali perbaikan. Tanda kurung pada pangkat menandakan nomor iterasi, bukan perpangkatan.
- $\mathbf{e}^{(s)}$, $\mathbf{J}^{(s)}$, $\mathbf{g}^{(s)}$, $\mathbf{H}^{(s)}$ adalah galat, matriks turunan, gradien, dan Hessian yang dihitung pada $\boldsymbol{\theta} = \boldsymbol{\theta}^{(s)}$.
- $\boldsymbol{\delta}^{(s)}$ adalah **vektor koreksi** berukuran $q \times 1$: besarnya perubahan setiap parameter pada iterasi ke-s, sehingga $\boldsymbol{\theta}^{(s+1)} = \boldsymbol{\theta}^{(s)} - \boldsymbol{\delta}^{(s)}$. Rumusnya diturunkan di bawah.
- $Q^{(s)} = Q(\boldsymbol{\theta}^{(s)})$ adalah jumlah kuadrat galat pada iterasi ke-s; iterasi yang baik membuat $Q^{(0)} > Q^{(1)} > Q^{(2)} > \cdots$.

6.2 Deret Taylor: mendekati fungsi dengan polinomial

Deret Taylor menyatakan bahwa fungsi mulus $f(\theta)$ di sekitar suatu titik θ_0 dapat didekati dengan polinomial yang dibangun dari turunan-turunannya di titik itu:

$$f(\theta) \approx f(\theta_0) + f'(\theta_0)(\theta - \theta_0) + \tfrac{1}{2} f''(\theta_0)(\theta - \theta_0)^2 + \tfrac{1}{6} f'''(\theta_0)(\theta - \theta_0)^3 + \cdots$$

Jika hanya dua suku pertama yang dipakai, diperoleh *pendekatan orde satu* (garis singgung). Jika tiga suku, *pendekatan orde dua* (parabola). Pendekatan ini makin akurat bila θ makin dekat dengan θ_0.

Contoh. Untuk $f(\theta) = e^{\theta}$ di sekitar $\theta_0 = 1$ (semua turunannya $e^1 = 2.7183$), pada $\theta = 1.2$:

$$\begin{aligned} \text{nilai sebenarnya:} \quad & e^{1.2} = 3.3201, \\ \text{orde satu:} \quad & e + e(0.2) = e(1 + 0.2) = 3.2619, \\ \text{orde dua:} \quad & e + e(0.2) + \tfrac{1}{2} e(0.2)^2 = e(1 + 0.2 + 0.02) = 3.3163. \end{aligned}$$

Pendekatan orde dua jauh lebih dekat dengan nilai sebenarnya.

Mengapa orde dua. Kita ingin mencari titik minimum. Pendekatan orde satu adalah garis lurus, yang tidak memiliki titik minimum (selalu naik atau selalu turun). Pendekatan orde dua adalah parabola, yang memiliki tepat satu titik minimum bila kelengkungannya positif, dan titik minimum parabola mudah dihitung. Orde tiga atau lebih tidak dipakai karena memerlukan turunan yang lebih tinggi dan minimumnya tidak dapat dihitung dengan rumus sederhana. Jadi orde dua adalah pendekatan paling sederhana yang masih memiliki minimum.

6.3 Metode Newton–Raphson dengan satu parameter

Gagasannya: di sekitar tebakan saat ini $\theta^{(s)}$, ganti $Q(\theta)$ dengan parabola Taylor orde dua, lalu jadikan titik minimum parabola itu sebagai tebakan berikutnya. Tulis $d = \theta - \theta^{(s)}$. Parabolanya

$$P(d) = Q(\theta^{(s)}) + Q'(\theta^{(s)})\, d + \tfrac{1}{2} Q''(\theta^{(s)})\, d^2.$$

Turunkan terhadap d dan samakan dengan nol: $Q'(\theta^{(s)}) + Q''(\theta^{(s)})\,d = 0$, sehingga $d = -Q'(\theta^{(s)})/Q''(\theta^{(s)})$. Maka

$$\theta^{(s+1)} = \theta^{(s)} - \frac{Q'(\theta^{(s)})}{Q''(\theta^{(s)})}. \tag{15}$$

Karena parabola hanya pendekatan, titik barunya belum tentu minimum yang sebenarnya; tetapi biasanya lebih dekat. Langkah ini diulang sampai $Q'(\theta^{(s)}) \approx 0$.

Contoh numerik. Minimumkan $Q(\theta) = e^{\theta} - 2\theta$. Turunannya $Q'(\theta) = e^{\theta} - 2$ dan $Q''(\theta) = e^{\theta}$; minimum sebenarnya di $\theta = \ln 2 = 0.693147$. Mulai dari $\theta^{(0)} = 0$:

s	$\theta^{(s)}$	$Q'(\theta^{(s)})$	$Q''(\theta^{(s)})$	koreksi Q'/Q''
0	0.000000	-1.000000	1.000000	-1.000000
1	1.000000	0.718282	2.718282	0.264241
2	0.735759	0.087065	2.087065	0.041717
3	0.694042	0.001791	2.001791	0.000895
4	0.693148	0.000001	2.000001	0.000000

Contoh baris pertama: $\theta^{(1)} = 0 - (-1)/1 = 1$. Baris kedua: $\theta^{(2)} = 1 - 0.718282/2.718282 = 0.735759$. Dalam empat iterasi, $\theta^{(s)}$ sudah sama dengan $\ln 2$ sampai enam desimal.

6.4 Newton–Raphson dengan banyak parameter

Untuk vektor $\boldsymbol{\theta}$, deret Taylor orde dua di sekitar $\boldsymbol{\theta}^{(s)}$ dengan $\mathbf{d} = \boldsymbol{\theta} - \boldsymbol{\theta}^{(s)}$ adalah

$$Q(\boldsymbol{\theta}^{(s)} + \mathbf{d}) \approx Q(\boldsymbol{\theta}^{(s)}) + \mathbf{g}'\mathbf{d} + \tfrac{1}{2}\,\mathbf{d}'\mathbf{H}\,\mathbf{d},$$

dengan $\mathbf{g} = \mathbf{g}^{(s)}$ dan $\mathbf{H} = \mathbf{H}^{(s)}$. Ini adalah perluasan langsung dari kasus satu parameter: $\mathbf{g}'\mathbf{d} = \sum_u g_u d_u$ menggantikan $Q'd$, dan $\mathbf{d}'\mathbf{H}\mathbf{d} = \sum_u \sum_v H_{uv} d_u d_v$ menggantikan $Q''d^2$.

Turunkan terhadap $\mathbf{d}$. Turunan $\mathbf{g}'\mathbf{d}$ terhadap $\mathbf{d}$ adalah $\mathbf{g}$, dan turunan $\frac{1}{2}\mathbf{d}'\mathbf{H}\mathbf{d}$ adalah $\mathbf{H}\mathbf{d}$ (karena $\mathbf{H}$ simetris). Samakan dengan nol:

$$\mathbf{g} + \mathbf{H}\mathbf{d} = \mathbf{0} \quad\Longrightarrow\quad \mathbf{d} = -\mathbf{H}^{-1}\mathbf{g}.$$

Definisikan vektor koreksi $\boldsymbol{\delta}^{(s)} = \mathbf{H}^{-1}\mathbf{g}$ (berukuran $q \times 1$). Maka langkah Newton–Raphson adalah

$$\boldsymbol{\theta}^{(s+1)} = \boldsymbol{\theta}^{(s)} + \mathbf{d} = \boldsymbol{\theta}^{(s)} - \boldsymbol{\delta}^{(s)}, \qquad \boldsymbol{\delta}^{(s)} = \left(\mathbf{H}^{(s)}\right)^{-1}\mathbf{g}^{(s)}, \tag{16}$$

yang untuk $q = 1$ kembali menjadi (15).

6.5 Metode Gauss–Newton

Newton–Raphson memerlukan Hessian lengkap. Pada model bilinear, Hessian diganti dengan pendekatannya $\mathbf{H} \approx 2\mathbf{J}'\mathbf{J}$ dari (14). Substitusikan $\mathbf{g} = 2\mathbf{J}'\mathbf{e}$ dan $\mathbf{H} = 2\mathbf{J}'\mathbf{J}$ ke (16); faktor 2 saling menghapus:

$$\boxed{\boldsymbol{\theta}^{(s+1)} = \boldsymbol{\theta}^{(s)} - \boldsymbol{\delta}^{(s)}, \qquad \boldsymbol{\delta}^{(s)} = \left(\mathbf{J}^{(s)\prime}\mathbf{J}^{(s)}\right)^{-1}\mathbf{J}^{(s)\prime}\mathbf{e}^{(s)}.} \tag{17}$$

Newton–Raphson dengan Hessian pendekatan ini disebut metode *Gauss–Newton*. Ukuran setiap objek: $\mathbf{J}^{(s)}$ berukuran $n \times q$, $\mathbf{J}^{(s)\prime}\mathbf{J}^{(s)}$ berukuran $q \times q$, $\mathbf{J}^{(s)\prime}\mathbf{e}^{(s)}$ berukuran $q \times 1$, sehingga $\boldsymbol{\delta}^{(s)}$ berukuran $q \times 1$.

Tafsiran sebagai regresi. Rumus $\boldsymbol{\delta}^{(s)} = (\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e}$ persis rumus penduga OLS $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ dengan $\mathbf{y} = \mathbf{e}$ dan $\mathbf{X} = \mathbf{J}$. Jadi **setiap iterasi adalah satu regresi OLS**: galat e_t sebagai variabel respons, turunan $\psi_{t,1}, \ldots, \psi_{t,q}$ sebagai variabel penjelas, tanpa konstanta. Koefisien regresinya adalah $\boldsymbol{\delta}^{(s)}$, lalu dikurangkan dari $\boldsymbol{\theta}^{(s)}$. Hal yang sama dapat dilihat dari linearisasi galat: $e_t(\boldsymbol{\theta}) \approx e_t(\boldsymbol{\theta}^{(s)}) + \boldsymbol{\psi}_t'\mathbf{d}$, sehingga $Q \approx \|\mathbf{e} + \mathbf{J}\mathbf{d}\|^2$, yang minimum pada $\mathbf{d} = -(\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e}$.

Pemeriksaan pada regresi linear. Jika model sebenarnya linear, $\mathbf{J} = -\mathbf{X}$ tetap dan Gauss–Newton memberi $\boldsymbol{\beta}^{(1)} = \boldsymbol{\beta}^{(0)} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}^{(0)}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$: penduga OLS tercapai dalam satu iterasi dari nilai awal mana pun. Pada model bilinear diperlukan beberapa iterasi karena $\mathbf{J}$ berubah setiap kali $\boldsymbol{\theta}$ berubah.

6.6 Kontrol ukuran langkah (*step-size control*)

Parabola Taylor hanya akurat di dekat $\boldsymbol{\theta}^{(s)}$. Jika $\boldsymbol{\delta}^{(s)}$ besar, titik baru bisa jatuh di daerah tempat pendekatan itu buruk, sehingga Q justru naik atau rekursi (3) meledak (nilai e_t menjadi sangat besar). Karena itu ukuran langkah perlu dikontrol. Dua cara yang umum:

- **Step-halving (line search sederhana).** Hitung $\boldsymbol{\theta}^{(s)} - \lambda\boldsymbol{\delta}^{(s)}$ dengan $\lambda = 1$. Jika Q tidak turun atau tidak hingga, ulangi dengan $\lambda = \frac{1}{2}$, lalu $\frac{1}{4}$, dan seterusnya, sampai Q turun. Arahnya tetap, hanya panjangnya dipendekkan.
- **Levenberg–Marquardt (damping).** Selesaikan $(\mathbf{J}'\mathbf{J} + \mu\,\mathrm{diag}(\mathbf{J}'\mathbf{J}))\boldsymbol{\delta} = \mathbf{J}'\mathbf{e}$ dengan $\mu \geq 0$. Untuk $\mu = 0$ langkahnya sama dengan Gauss–Newton; untuk μ besar langkahnya pendek dan searah $-\mathbf{g}$ (arah penurunan tercuram). Nilai μ diperbesar jika Q naik dan diperkecil jika Q turun.

Karena $\mathbf{J}'\mathbf{J}$ semi-definit positif (Bagian 5), arah $-\boldsymbol{\delta}^{(s)}$ selalu arah penurunan, sehingga dengan langkah yang cukup pendek Q pasti turun.

6.7 Kriteria berhenti (*stopping rule*)

Iterasi dihentikan bila salah satu terpenuhi:

1. perubahan relatif Q sangat kecil: $|Q^{(s)} - Q^{(s+1)}|/Q^{(s)} < \varepsilon$, misalnya $\varepsilon = 10^{-8}$;
2. vektor koreksi sangat kecil: $\max_u |\delta_u^{(s)}| < \varepsilon_\theta$;
3. jumlah iterasi mencapai batas $s_{\max}$ (misalnya 100); dalam hal ini hasil perlu diperiksa karena belum tentu konvergen.

Implementasi asli penulis. Subba Rao & Gabr (1984) menyertakan program komputer yang mereka pakai. Program itu memakai gradien tanpa faktor 2 (yaitu $\mathbf{J}'\mathbf{e}$) bersama $\mathbf{H} = 2\mathbf{J}'\mathbf{J}$, sehingga koreksinya $\frac{1}{2}(\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e}$: selalu *setengah langkah* Gauss–Newton. Program itu juga membagi data dengan 100 sebelum pendugaan, berhenti jika perubahan $\hat{\sigma}^2$ kurang dari 10^{-5} atau setelah 20 iterasi, dan menganggap pendugaan gagal jika jumlah kuadrat galat melebihi 10^{50}. Setengah langkah mencapai titik yang sama dengan langkah penuh, hanya lebih lambat (Gambar 1).

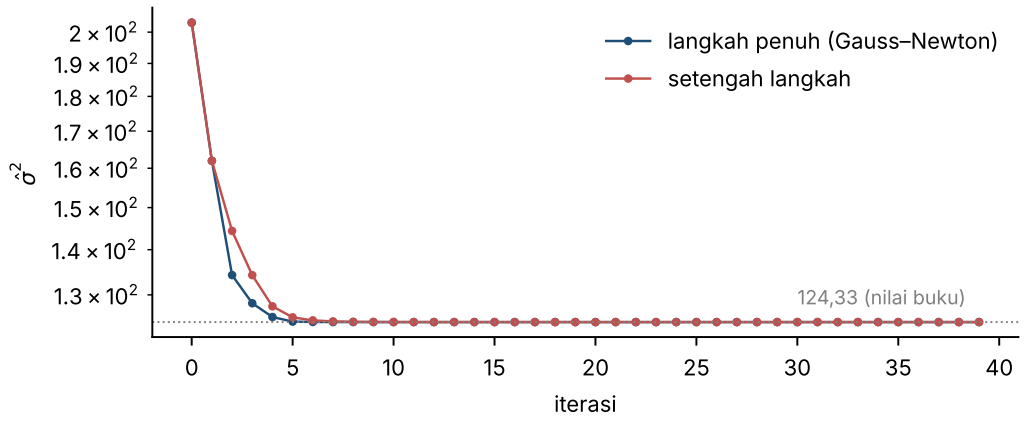


Figure 1: Konvergensi $\hat{\sigma}^2$ untuk Model S (data sunspot, Bagian 16), mulai dari model AR dengan semua $b = 0$. Langkah penuh dan setengah langkah berakhir di titik yang sama, $\hat{\sigma}^2 = 124{,}33$.

6.8 Algoritma

Contoh perhitungan algoritma ini secara manual untuk dua iterasi diberikan di Bagian 14.

Algoritma 1: Pendugaan model bilinear subset dengan struktur $(\mathcal{K}, \mathcal{B})$ tetap

Masukan: data $X_1, \ldots, X_N$; lag terbesar γ; lag AR $\mathcal{K}$; pasangan bilinear $\mathcal{B}$; nilai awal $\boldsymbol{\theta}^{(0)}$; toleransi ε

Keluaran: $\hat{\boldsymbol{\theta}}$, $\hat{\sigma}^2$, matriks $\mathbf{J}$, residual $\hat{e}_t$

$s \leftarrow 0$;
repeat
  Set $e_t = 0$ dan $\psi_{t,u} = 0$ untuk $t \le \gamma$;
  for $t = \gamma + 1, \ldots, N$ **do**
    hitung e_t dengan (3) dan $\psi_{t,u}$ dengan (10), memakai $\boldsymbol{\theta}^{(s)}$;
  $Q^{(s)} \leftarrow \sum_t e_t^2$; $\boldsymbol{\delta}^{(s)} \leftarrow (\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e}$;
  $\lambda \leftarrow 1$;
  while $Q(\boldsymbol{\theta}^{(s)} - \lambda\boldsymbol{\delta}^{(s)})$ *tidak hingga* ***atau*** $> Q^{(s)}$ **do**
    $\lambda \leftarrow \lambda/2$; `// step-halving`
  $\boldsymbol{\theta}^{(s+1)} \leftarrow \boldsymbol{\theta}^{(s)} - \lambda\boldsymbol{\delta}^{(s)}$; $s \leftarrow s + 1$;
until $|Q^{(s-1)} - Q^{(s)}|/Q^{(s-1)} < \varepsilon$ ***atau*** $s = s_{\max}$;
$\hat{\boldsymbol{\theta}} \leftarrow \boldsymbol{\theta}^{(s)}$; $\hat{\sigma}^2 \leftarrow Q(\hat{\boldsymbol{\theta}})/n$;

7 Nilai awal

Fungsi $Q(\boldsymbol{\theta})$ dapat memiliki lebih dari satu minimum lokal. Iterasi akan berhenti di minimum yang "terdekat" dari titik awal, sehingga nilai awal sangat menentukan hasil.

7.1 Dari model autoregresif

Pilihan alami: mulai dari model tanpa suku bilinear. Pasang model AR dengan lag $\mathcal{K}$ dan konstanta,

$$X_t = -\sum_{k \in \mathcal{K}} a_k X_{t-k} + \alpha + e_t,$$

dengan OLS biasa (regresikan X_t pada $-X_{t-k}$ dan kolom konstanta 1, untuk $t = \gamma+1, \ldots, N$), lalu set semua $b_{ij} = 0$.

Jika model AR dipasang pada data terpusat $x_t = X_t - \bar{X}$ (tanpa konstanta), konstanta untuk data asli diperoleh dengan mensubstitusikan $x_t = X_t - \bar{X}$ ke $x_t + \sum a_k x_{t-k} = e_t$:

$$X_t - \bar{X} + \sum a_k (X_{t-k} - \bar{X}) = e_t \implies X_t + \sum a_k X_{t-k} = \bar{X}\Big(1 + \sum_{k \in \mathcal{K}} a_k\Big) + e_t,$$

sehingga $\alpha = \bar{X}(1 + \sum a_k)$.

7.2 Metode residual berulang

Gagasan: jika e_{t-j} dianggap *diketahui*, model (2) menjadi linear dalam semua parameter, karena $X_{t-i}e_{t-j}$ hanyalah sebuah variabel penjelas. Maka:

1. mulai dari residual suatu model awal (misalnya residual AR);
2. regresikan X_t pada $\{-X_{t-k}\}$, $\{X_{t-i}e_{t-j}\}$, dan 1 dengan OLS, memakai residual yang tetap;
3. hitung ulang e_t dengan (3) memakai parameter baru;
4. ulangi beberapa kali (misalnya maksimum 5) atau sampai $\hat{\sigma}^2$ hampir tidak berubah.

Hasilnya dapat dipakai sebagai nilai awal Algoritma 1. Metode ini tidak dijamin menurunkan Q: pada Model S, lima putaran justru menaikkan $\hat{\sigma}^2$ menjadi sekitar 7360, walaupun Gauss–Newton setelahnya tetap mencapai 124,33.

7.3 Nilai awal bertahap

Saat model dibangun dengan menambahkan suku bilinear satu per satu (Bagian 8), nilai awal untuk model yang lebih besar diambil dari model sebelumnya: semua parameter lama memakai dugaan dari model sebelumnya, dan koefisien suku baru diberi nilai awal 0. Strategi ini terbukti penting. Untuk Model L1 (Bagian 16), menduga keenam suku bilinear sekaligus dari nilai awal AR berakhir di minimum lokal dengan $\hat{\sigma}^2 = 0{,}0256$, sedangkan penambahan bertahap mencapai $\hat{\sigma}^2 = 0{,}0223$.

7.4 Banyak titik awal (multi-start)

Untuk berjaga-jaga terhadap minimum lokal, jalankan Algoritma 1 dari beberapa nilai awal untuk koefisien b (misalnya $b^{(0)} \in \{-0.4, -0.2, 0, 0.2, 0.4\}$, disesuaikan dengan skala data) dan ambil hasil dengan Q terkecil. Bagian 15 menunjukkan bahwa langkah sederhana ini menghilangkan hampir semua kegagalan.

8 Pemilihan model

8.1 Kriteria informasi Akaike

AIC didefinisikan sebagai $-2\log L(\hat{\boldsymbol{\theta}}, \hat{\sigma}^2) + 2q$, dengan q banyaknya parameter. Dari (8),

$$-2\log L(\hat{\boldsymbol{\theta}}, \hat{\sigma}^2) = n(1 + \log 2\pi) + n \log \frac{Q(\hat{\boldsymbol{\theta}})}{n} = n \log \hat{\sigma}^2 + n(1 + \log 2\pi).$$

Suku $n(1+\log 2\pi)$ sama untuk semua model pada data yang sama, sehingga dapat dibuang. Diperoleh

$$\boxed{\mathrm{AIC} = n\log\hat{\sigma}^2 + 2q, \qquad \mathrm{NAIC} = \frac{\mathrm{AIC}}{n} = \log\hat{\sigma}^2 + \frac{2q}{n}.} \tag{18}$$

NAIC (AIC ternormalisasi) adalah bentuk yang dilaporkan Subba Rao & Gabr (1984). Banyaknya parameter q mencakup konstanta α (atau rata-rata, untuk model AR pada data terpusat), tetapi tidak mencakup σ^2. Karena σ^2 ada di semua model, menghitung atau tidak menghitungnya tidak mengubah urutan model. Model dengan AIC terkecil dipilih.

Table 1: Pemeriksaan rumus (18) terhadap angka yang dilaporkan Subba Rao & Gabr (1984). Model-modelnya dijelaskan di Bagian 16.

Data	Model	$\hat{\sigma}^2$	q	n	NAIC dihitung	NAIC dilaporkan
Sunspot	AR(9)	199.27	10	211	5.389	5.39
Sunspot	subset AR lag $\{1,2,9\}$	203.21	4	211	5.352	5.352
Sunspot	Model S	124.33	11	211	4.927	4.927
Log lynx	Model L1	0.0223	13	88	-3.508	-3.508

8.2 Prosedur pemilihan bertahap

1. **Tetapkan** γ (lag terbesar) dan $n = N - \gamma$.
2. **Orde AR penuh.** Pasang AR orde $1, 2, \ldots, \gamma$ dengan OLS pada pengamatan $t = \gamma + 1, \ldots, N$; pilih orde p dengan AIC terkecil.
3. **Subset AR.** Di antara semua himpunan bagian tak kosong dari $\{1, \ldots, p\}$ (sebanyak $2^p - 1$), pilih yang AIC-nya terkecil. Untuk $p \le 12$ ini paling banyak 4095 regresi OLS, sehingga dapat dicari secara menyeluruh. Pada data sunspot dan log lynx, pencarian menyeluruh menghasilkan subset yang sama dengan yang dilaporkan Subba Rao & Gabr (1984), yang memakai algoritma pencarian lain.
4. **Suku bilinear pertama.** Tetapkan ξ dengan $p \le \xi \le \gamma$ dan himpunan kandidat $T_1 = \{(i,j) : 1 \le i, j \le \xi\}$. Untuk setiap $(i,j) \in T_1$, pasang model subset AR ditambah satu suku $b_{ij} X_{t-i} e_{t-j}$ dengan Algoritma 1; pilih pasangan (r_1, s_1) dengan AIC terkecil.
5. **Suku berikutnya.** Ulangi dengan kandidat $T_2 = T_1 \setminus \{(r_1, s_1)\}$, memakai nilai awal bertahap, dan seterusnya.
6. **Berhenti** jika penambahan suku tidak lagi menurunkan AIC.

Catatan

Prosedur bertahap dengan $\xi = 9$ yang dijalankan ulang pada data sunspot memilih enam suku pertama Model S dalam urutan yang persis sama: $(2,1), (8,1), (1,3), (4,3), (1,6), (2,4)$. Pada langkah ketujuh, prosedur memilih $(8,5)$ dengan $\hat{\sigma}^2 = 120{,}2$, sedangkan Model S memuat $(3,2)$. Gambar 2 menunjukkan bahwa suku $(3,2)$ sebenarnya menaikkan NAIC. Jadi aturan berhenti yang dipakai dalam laporan asli tidak sepenuhnya konsisten. Disarankan aturan yang tegas: berhenti saat AIC naik, dan tolak kandidat yang tidak invertibel (Bagian 10).

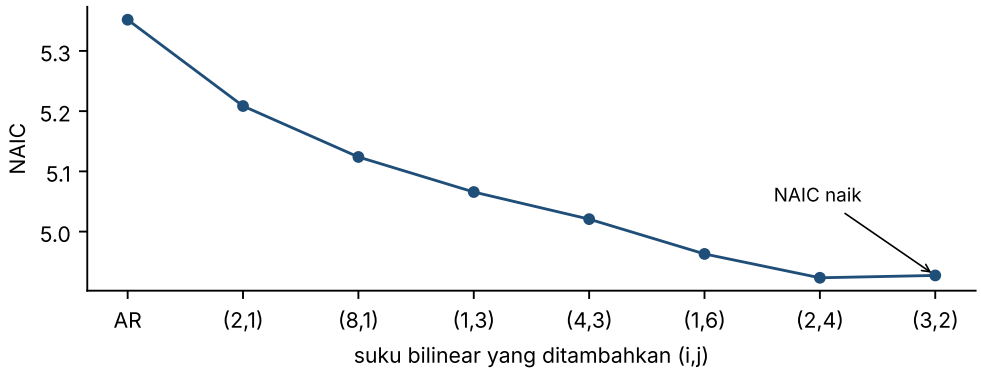


Figure 2: Lintasan NAIC saat suku bilinear Model S ditambahkan satu per satu dalam urutan yang dilaporkan Subba Rao & Gabr (1984). Suku terakhir, $(3, 2)$, menaikkan NAIC dari 4.9233 ke 4.9272; nilai-t koefisiennya hanya 1.2.

9 Galat baku (*standard error*)

9.1 Penurunan

Di sekitar dugaan $\hat{\boldsymbol{\theta}}$, linearisasi galat seperti pada Bagian 6 memberi model regresi pendekatan

$$\mathbf{e}(\boldsymbol{\theta}_0) \approx \mathbf{e}(\hat{\boldsymbol{\theta}}) + \mathbf{J}(\boldsymbol{\theta}_0 - \hat{\boldsymbol{\theta}}),$$

dengan $\boldsymbol{\theta}_0$ parameter sebenarnya dan $\mathbf{e}(\boldsymbol{\theta}_0)$ galat sebenarnya yang i.i.d. $N(0, \sigma^2)$. Susun ulang menjadi $\mathbf{e}(\hat{\boldsymbol{\theta}}) \approx \mathbf{J}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) + \mathbf{e}(\boldsymbol{\theta}_0)$, yaitu persamaan regresi linear dengan "koefisien" $\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0$. Karena $\hat{\boldsymbol{\theta}}$ meminimumkan jumlah kuadrat, berlaku $\mathbf{J}'\mathbf{e}(\hat{\boldsymbol{\theta}}) = \mathbf{0}$ (gradien nol), dan dari sini

$$\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0 \approx -(\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e}(\boldsymbol{\theta}_0).$$

Dengan memperlakukan $\mathbf{J}$ sebagai tetap, $\operatorname{Var}(\mathbf{J}'\mathbf{e}(\boldsymbol{\theta}_0)) = \sigma^2\mathbf{J}'\mathbf{J}$, sehingga

$$\boxed{\widehat{\operatorname{Cov}}(\hat{\boldsymbol{\theta}}) = \hat{\sigma}^2(\mathbf{J}'\mathbf{J})^{-1}, \qquad \operatorname{SE}(\hat{\theta}_u) = \sqrt{\left[\hat{\sigma}^2(\mathbf{J}'\mathbf{J})^{-1}\right]_{uu}}.} \tag{19}$$

Hasil yang sama diperoleh dari matriks informasi Fisher: turunan kedua $-\log L$ terhadap $\boldsymbol{\theta}$ adalah $\frac{1}{2\sigma^2}\mathbf{H} = \frac{1}{\sigma^2}\mathbf{J}'\mathbf{J}$, dan invers matriks informasi memberi (19). Matriks $\mathbf{J}$ adalah yang sama dengan yang dipakai pada iterasi terakhir.

Batas ketepatan galat baku

Penurunan di atas bersifat pendekatan. Untuk model bilinear umum, distribusi asimtotik penduga belum dibuktikan secara umum; hasil yang ada hanya untuk kasus khusus dan memerlukan syarat momen yang berat (misalnya Grahn, 1995, memerlukan $\mathbb{E}X_t^8 < \infty$). Ling, Peng & Zhu juga menyatakan bahwa teori asimtotik umum untuk model ini belum mapan. Simulasi di Bagian 15 menunjukkan bahwa (19) cukup baik untuk koefisien AR dan konstanta, tetapi agak terlalu kecil untuk b. Untuk kesimpulan formal, bootstrap parametrik lebih aman.

9.2 Uji signifikansi parameter

Uji ini memeriksa apakah suatu parameter berbeda nyata dari nol, yaitu apakah suku yang bersangkutan memang berperan dalam model.

Hipotesis. Untuk parameter ke-u (a_k, b_{ij}, c_l, atau α):

$$H_0 : \ \theta_u = 0 \qquad \text{vs} \qquad H_1 : \ \theta_u \neq 0.$$

H_0 menyatakan suku yang memuat θ_u tidak berpengaruh terhadap X_t. Misalnya $H_0 : b_{ij} = 0$ berarti interaksi $X_{t-i}e_{t-j}$ tidak diperlukan. H_1 menyatakan suku itu berpengaruh.

Statistik uji. Dengan galat baku dari (19),

$$t_u = \frac{\hat{\theta}_u - 0}{\mathrm{SE}(\hat{\theta}_u)} = \frac{\hat{\theta}_u}{\sqrt{\left[\hat{\sigma}^2(\mathbf{J}'\mathbf{J})^{-1}\right]_{uu}}} \overset{H_0}{\approx} N(0,1).$$

Bentuknya sama dengan uji-t pada regresi linear: dugaan dibagi galat bakunya. Distribusinya hanya *pendekatan* untuk n besar, karena penduga pada model bilinear bersifat nonlinear. Untuk sampel kecil, distribusi t dengan derajat bebas $n - q$ sering dipakai sebagai pendekatan yang lebih hati-hati; untuk n besar keduanya hampir sama.

Keputusan. Pada taraf nyata α, tolak H_0 jika $|t_u| > z_{\alpha/2}$ (misalnya 1.96 untuk $\alpha = 5\%$), atau jika

$$p\text{-value} = 2\big(1 - \Phi(|t_u|)\big) < \alpha.$$

Secara setara, H_0 ditolak jika selang kepercayaan $100(1-\alpha)\%$, yaitu $\hat{\theta}_u \pm z_{\alpha/2}\,\mathrm{SE}(\hat{\theta}_u)$, tidak memuat nol.

Contoh (Model S, Bagian 16).

- $\hat{b}_{2,1} = -0.014575$, SE $= 0.001018$, sehingga $t = -14.3$. Karena $|t| > 1.96$, $H_0 : b_{2,1} = 0$ ditolak; suku $X_{t-2}e_{t-1}$ berpengaruh nyata. Selang kepercayaan 95%: $-0.014575 \pm 1.96(0.001018) = (-0.0166, -0.0126)$, tidak memuat nol.
- $\hat{b}_{3,2} = 0.001781$, SE $= 0.001487$, sehingga $t = 1.20$ dan p-value $= 2(1 - \Phi(1.20)) = 0.23$. Karena $|t| < 1.96$, $H_0 : b_{3,2} = 0$ tidak ditolak; tidak ada bukti bahwa suku $X_{t-3}e_{t-2}$ diperlukan. Ini sejalan dengan Gambar 2: menambahkan suku ini justru menaikkan NAIC.

Hati-hati dengan uji untuk koefisien bilinear

Ketepatan uji ini bergantung pada ketepatan galat baku. Studi simulasi (Bagian 15) menunjukkan galat baku untuk b cenderung terlalu kecil (peluang cakupan selang 95% hanya 91.5%). Akibatnya nilai $|t|$ untuk b cenderung terlalu besar, sehingga $H_0 : b_{ij} = 0$ lebih sering ditolak daripada seharusnya. Untuk koefisien b yang nilai $|t|$-nya dekat batas kritis, kesimpulan sebaiknya dikonfirmasi dengan selang kepercayaan bootstrap. Untuk koefisien AR dan konstanta, uji ini lebih dapat diandalkan.

10 Invertibilitas

10.1 Mengapa penting

Galat $e_t(\boldsymbol{\theta})$ dihitung dengan nilai awal (4) yang sebenarnya keliru. Galat hasil hitungan hanya mendekati galat sebenarnya jika pengaruh nilai awal yang keliru itu menghilang seiring waktu.

Granger & Andersen (1978) menyebut model *invertibel* jika $\mathbb{E}(e_t - \hat{e}_t)^2 \to 0$ untuk $t \to \infty$, dengan $\hat{e}_t$ galat hasil rekonstruksi. Jika model tidak invertibel, $Q(\boldsymbol{\theta})$ tidak lagi mengukur kesesuaian model, dan minimisasi dapat menghasilkan $\hat{\sigma}^2$ kecil yang semu.

10.2 Persamaan perambatan kesalahan nilai awal

Misalkan e_t adalah galat sebenarnya dan $\hat{e}_t$ galat yang dihitung dengan nilai awal berbeda; keduanya memenuhi (3) dengan data dan parameter yang sama:

$$\hat{e}_t = X_t + \sum a_k X_{t-k} - \alpha - \sum b_{ij} X_{t-i}\, \hat{e}_{t-j},$$
$$e_t = X_t + \sum a_k X_{t-k} - \alpha - \sum b_{ij} X_{t-i}\, e_{t-j}.$$

Kurangkan persamaan kedua dari yang pertama. Semua suku yang tidak memuat galat saling menghapus. Dengan $\delta_t = \hat{e}_t - e_t$:

$$\boxed{\delta_t = -\sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i}\, \delta_{t-j}} \tag{20}$$

(ditambah $-\sum c_j \delta_{t-j}$ jika ada suku MA). Model invertibel jika $\delta_t \to 0$.

10.3 Kasus satu suku bilinear

Untuk $X_t = bX_{t-i}e_{t-j} + e_t$, persamaan (20) menjadi $\delta_t = -bX_{t-i}\delta_{t-j}$. Dengan menerapkannya berulang setiap j langkah,

$$|\delta_t| = |bX_{t-i}| \cdot |bX_{t-i-j}| \cdot |bX_{t-i-2j}| \cdots |\delta_{\text{awal}}|, \qquad \log|\delta_t| = \sum_{\ell} \log|bX_{t-i-\ell j}| + \log|\delta_{\text{awal}}|.$$

Jumlah di ruas kanan memuat sekitar t/j suku. Untuk deret stasioner dan ergodik, rata-rata suku-suku itu mendekati ekspektasinya (teorema ergodik, versi hukum bilangan besar untuk deret waktu), sehingga $\frac{1}{t}\log|\delta_t| \to \frac{1}{j}\mathbb{E}\log|bX_t|$. Jadi $\delta_t \to 0$ jika

$$\mathbb{E}\log|b\,X_t| < 0.$$

Syarat yang melibatkan ekspektasi logaritma nilai mutlak ini sesuai dengan hasil Quinn (1982) untuk model bilinear satu parameter.

10.4 Diagnostik praktis

Untuk model umum tidak ada rumus tertutup. Gunakan (20) secara numerik: set $\delta_t = 1$ untuk $t \le \gamma$, jalankan (20) dengan data dan $\hat{\boldsymbol{\theta}}$ sampai $t = N$, lalu periksa $\log_{10}|\delta_N|$. Nilai yang sangat negatif berarti pengaruh nilai awal hilang (invertibel); nilai positif berarti pengaruhnya membesar (tidak invertibel).

11 Uji residual

Jika model sesuai, galat e_t saling bebas dan berdistribusi normal, sehingga residual $\hat{e}_t$ harus menyerupai barisan i.i.d. normal. Dua uji di bawah memeriksa kedua sifat itu. Pada bagian ini N menyatakan banyaknya residual, dan $z_{\alpha/2}$ kuantil atas normal baku ($z_{0.025} = 1.96$ untuk taraf nyata 5%).

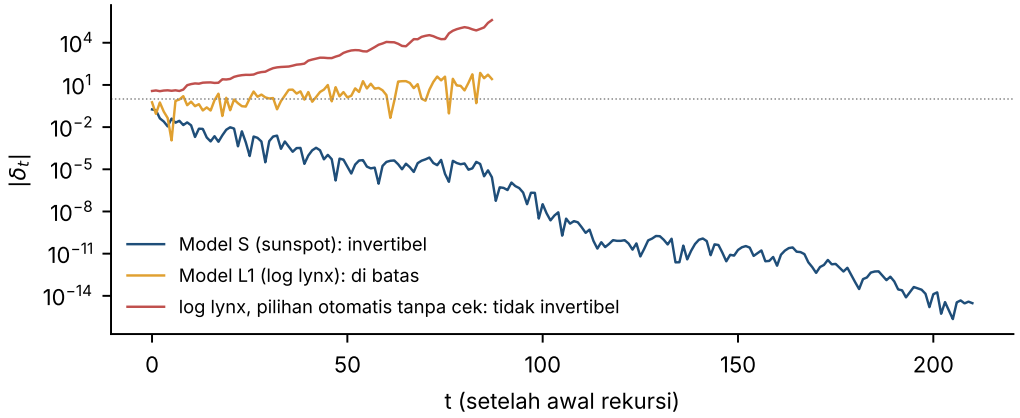


Figure 3: Perambatan kesalahan nilai awal (20). Model S jelas invertibel ($|\delta| \approx 10^{-14}$ di akhir). Model L1 berada di batas ($|\delta|$ membesar sekitar 70 kali). Model yang dipilih otomatis tanpa pemeriksaan invertibilitas membesar sekitar 10^4 kali, walaupun $\hat{\sigma}^2$-nya (0.0114) tampak jauh lebih baik daripada Model L1 (0.0223).

11.1 Uji independensi W

Residual bisa tidak berkorelasi tetapi tetap tidak saling bebas; ketergantungan semacam itu sering terlihat pada kuadratnya (misalnya periode dengan residual besar cenderung diikuti residual besar). Uji ini memeriksa autokorelasi lag 1 dari kuadrat galat. Misalkan $y_t = e_t^2$ dengan autokorelasi populasi $\rho_y(1) = \mathrm{Corr}(e_t^2, e_{t+1}^2)$.

Hipotesis.

$$H_0 : \ \rho_y(1) = 0 \qquad \text{vs} \qquad H_1 : \ \rho_y(1) \neq 0.$$

H_0 menyatakan tidak ada korelasi antara kuadrat galat yang berurutan, yang pasti berlaku jika galat saling bebas. H_1 menyatakan kuadrat galat berkorelasi, artinya galat tidak saling bebas: masih ada struktur yang belum ditangkap model. Perhatikan bahwa gagal menolak H_0 tidak membuktikan independensi; uji ini hanya memeriksa salah satu akibatnya.

Statistik uji. Dengan $y_t = \hat{e}_t^2$, $\bar{y}$ rata-ratanya, dan

$$\hat{R}_y(s) = \frac{1}{N}\sum_{t=1}^{N-s}(y_t - \bar{y})(y_{t+s} - \bar{y}), \qquad \hat{\rho}_y(1) = \frac{\hat{R}_y(1)}{\hat{R}_y(0)}, \qquad \hat{R}_y(0,1,1) = \frac{1}{N}\sum_{t=1}^{N-1}(y_t - \bar{y})^2(y_{t+1} - \bar{y})^2.$$

Di bawah H_0, $\hat{R}_y(1)$ adalah rata-rata dari $N-1$ suku $(y_t - \bar{y})(y_{t+1} - \bar{y})$ yang tidak berkorelasi, masing-masing dengan varians $R_y(0,1,1) = \mathbb{E}[(y_t - \mu_y)^2(y_{t+1} - \mu_y)^2]$, sehingga $\mathrm{Var}(\hat{R}_y(1)) \approx R_y(0,1,1)/N$. Statistik ujinya

$$W = \frac{\hat{\rho}_y(1)\,\hat{R}_y(0)\sqrt{N}}{\sqrt{\hat{R}_y(0,1,1)}} = \frac{\sqrt{N}\,\hat{R}_y(1)}{\sqrt{\hat{R}_y(0,1,1)}} \overset{H_0}{\approx} N(0,1).$$

Keputusan. Tolak H_0 pada taraf nyata α jika $|W| > z_{\alpha/2}$, atau jika p-value $= 2\big(1-\Phi(|W|)\big) < \alpha$, dengan Φ fungsi distribusi normal baku.

11.2 Uji normalitas (Lomnicki)

Distribusi normal memiliki kemencengan (*skewness*) nol dan kurtosis berlebih (*excess kurtosis*) nol. Untuk galat dengan rata-rata μ dan simpangan baku σ,

$$\gamma_1 = \frac{\mathbb{E}(e_t - \mu)^3}{\sigma^3}, \qquad \gamma_2 = \frac{\mathbb{E}(e_t - \mu)^4}{\sigma^4} - 3.$$

Hipotesis. Dua hipotesis diuji terpisah:

$$H_0 : \ \gamma_1 = 0 \ \text{ vs } \ H_1 : \ \gamma_1 \neq 0 \qquad \text{dan} \qquad H_0 : \ \gamma_2 = 0 \ \text{ vs } \ H_1 : \ \gamma_2 \neq 0.$$

Pada uji pertama, H_0 menyatakan distribusi galat simetris seperti normal, dan H_1 menyatakan distribusinya menceng ke kanan ($\gamma_1 > 0$) atau ke kiri ($\gamma_1 < 0$). Pada uji kedua, H_0 menyatakan ketebalan ekor distribusi sama dengan normal, dan H_1 menyatakan ekornya lebih tebal ($\gamma_2 > 0$, lebih sering muncul nilai ekstrem) atau lebih tipis ($\gamma_2 < 0$). Jika salah satu H_0 ditolak, asumsi normalitas tidak didukung data.

Statistik uji. Dengan $m_k = \frac{1}{N}\sum(\hat{e}_t - \bar{e})^k$, penduga kemencengan dan kurtosis berlebih adalah

$$G_1 = \frac{m_3}{m_2^{3/2}}, \qquad G_2 = \frac{m_4}{m_2^2} - 3.$$

Lomnicki (1961) menunjukkan bahwa untuk deret Gaussian stasioner,

$$\mathrm{Var}(G_1) \approx \frac{6}{N}\sum_s \rho_e^2(s), \qquad \mathrm{Var}(G_2) \approx \frac{24}{N}\sum_s \rho_e^4(s),$$

dengan $\rho_e(s)$ autokorelasi residual (untuk residual i.i.d. jumlahnya bernilai 1, sehingga $\mathrm{Var}(G_1) \approx 6/N$ dan $\mathrm{Var}(G_2) \approx 24/N$). Statistik ujinya

$$u_1 = \frac{G_1}{\sqrt{\mathrm{Var}(G_1)}} \overset{H_0}{\approx} N(0,1), \qquad u_2 = \frac{G_2}{\sqrt{\mathrm{Var}(G_2)}} \overset{H_0}{\approx} N(0,1).$$

Keputusan. Tolak $H_0 : \gamma_1 = 0$ jika $|u_1| > z_{\alpha/2}$, dan tolak $H_0 : \gamma_2 = 0$ jika $|u_2| > z_{\alpha/2}$. Kedua uji dapat digabung: di bawah normalitas, u_1 dan u_2 secara asimtotik saling bebas, sehingga $u_1^2 + u_2^2 \approx \chi^2_2$ (gagasan yang sama dengan uji Jarque–Bera); tolak normalitas jika $u_1^2 + u_2^2 > \chi^2_{2;\alpha}$ ($= 5.99$ untuk $\alpha = 5\%$).

Perbedaan dengan rumus yang tercetak di buku

Subba Rao & Gabr (1984) menuliskan $\mathrm{Var}(G_1) = 6\sum\rho_e^2(s)$ dan $\mathrm{Var}(G_2) = 24\sum\rho_e^4(s)$ tanpa faktor $1/N$, dan nilai u_1, u_2 yang mereka laporkan hanya dapat direproduksi dengan rumus tanpa $1/N$ itu. Faktor $1/N$ seharusnya ada, sebab kemencengan sampel dari N pengamatan normal memiliki varians sekitar $6/N$.

Untuk Model S pada taraf 5%: $|W| = 1.561 < 1.96$, jadi $H_0 : \rho_y(1) = 0$ tidak ditolak. Dengan rumus yang benar, $|u_1| = 4.40 > 1.96$ dan $|u_2| = 2.91 > 1.96$, jadi kedua H_0 ditolak: residual menceng ke kanan ($G_1 = 0.74$) dan berekor tebal. Kesimpulan ini berbeda dengan kesimpulan buku, yang memakai rumus tanpa $1/N$. Untuk model AR(9), $|W| = 2.46 > 1.96$, sehingga H_0 independensi ditolak; model bilinear menghilangkan ketergantungan ini.

Table 2: Uji residual pada data sunspot ($N = 211$ residual).

Model	Statistik	Dilaporkan buku	Rumus tanpa $1/N$	Rumus dengan $1/N$
AR(9)	W	2.459	2.457	
	u_1	0.333	0.329	4.77
	u_2	0.360	0.361	5.24
Model S	W	1.561	1.561	
	u_1	0.302	0.303	4.40
	u_2	0.200	0.200	2.91

11.3 Tindak lanjut jika uji tidak terpenuhi

Jika H_0 independensi ditolak. Kuadrat residual yang berkorelasi berarti masih ada struktur nonlinear (atau varians bersyarat yang berubah) yang belum ditangkap model. Langkah yang dapat dicoba:

1. Periksa autokorelasi kuadrat residual pada beberapa lag sekaligus (misalnya statistik Ljung–Box pada $\hat{e}_t^2$, dikenal sebagai uji McLeod–Li) untuk melihat lag mana yang bermasalah. Periksa juga autokorelasi residual biasa $\hat{e}_t$; jika signifikan, tambahkan lag AR.
2. Tambahkan suku bilinear: lanjutkan prosedur bertahap (Bagian 8) atau perbesar ξ, terutama pada lag yang ditunjukkan langkah 1.
3. Periksa invertibilitas model (Bagian 10). Pada model yang tidak invertibel, residual tidak merekonstruksi galat dengan benar, sehingga uji residual tidak bermakna.
4. Jika penambahan suku bilinear tidak menghilangkan ketergantungan, pertimbangkan kelas model lain yang memodelkan varians bersyarat secara langsung, misalnya ARCH/GARCH, atau model ambang (*threshold*).

Jika H_0 normalitas ditolak.

1. Periksa pencilan (*outlier*): residual yang sangat besar bisa berasal dari kesalahan data atau kejadian luar biasa. Normalitas sering ditolak hanya karena beberapa pengamatan.
2. Dugaan parameter tetap dapat dipakai sebagai penduga *conditional least squares*, karena meminimumkan $Q(\boldsymbol{\theta})$ tidak memerlukan asumsi normal. Yang terpengaruh adalah inferensinya: galat baku (19), AIC, dan selang peramalan yang diturunkan dari distribusi normal menjadi kurang tepat.
3. Untuk inferensi, gunakan bootstrap residual: bangkitkan data baru dari model dugaan dengan galat diambil acak (dengan pengembalian) dari residual $\hat{e}_t$, duga ulang parameternya, dan gunakan sebaran dugaan-dugaan itu untuk galat baku dan selang kepercayaan.
4. Untuk peramalan dengan simulasi Monte Carlo (Bagian 12), ambil galat masa depan dari residual $\hat{e}_t$, bukan dari $N(0, \hat{\sigma}^2)$.
5. Pertimbangkan transformasi data (log, akar, atau Box–Cox) sebelum pemodelan. Perhatikan bahwa peramalan yang ditransformasi balik menjadi bias dan perlu dikoreksi.

12 Peramalan

Peramalan optimal (dalam arti *mean squared error* terkecil) untuk X_{t+h} dengan informasi sampai waktu t adalah ekspektasi bersyaratnya, $\hat{X}_t(h) = \mathbb{E}(X_{t+h} \mid \mathcal{F}_t)$. Dengan asumsi invertibel, $e_1, \ldots, e_t$ dapat dihitung dari data, sedangkan $e_{t+1}, e_{t+2}, \ldots$ belum terjadi, saling bebas, berekspektasi 0 dan bervarians σ^2.

12.1 Satu langkah ke depan

Dari (2) untuk waktu $t+1$: $X_{t+1} = \mu_{t+1} + e_{t+1}$ dengan μ_{t+1} hanya memuat besaran sampai waktu t. Maka

$$\hat{X}_t(1) = \mu_{t+1} = -\sum_k a_k X_{t+1-k} + \alpha + \sum_{(i,j)} b_{ij} X_{t+1-i} e_{t+1-j}, \qquad X_{t+1} - \hat{X}_t(1) = e_{t+1}.$$

Jadi galat peramalan satu langkah di luar sampel diperoleh hanya dengan meneruskan rekursi (3) pada data baru dengan $\hat{\boldsymbol{\theta}}$.

12.2 Dua langkah atau lebih: penurunan pada contoh

Ambil $X_t + aX_{t-1} = \alpha + bX_{t-1}e_{t-1} + e_t$. Untuk $h = 2$:

$$X_{t+2} = -aX_{t+1} + \alpha + bX_{t+1}e_{t+1} + e_{t+2}.$$

Ambil ekspektasi bersyarat suku demi suku:

- $\mathbb{E}(X_{t+1} \mid \mathcal{F}_t) = \hat{X}_t(1)$ dan $\mathbb{E}(e_{t+2} \mid \mathcal{F}_t) = 0$.
- Suku bilinear memuat X_{t+1} dan e_{t+1} yang keduanya belum terjadi dan *tidak saling bebas*, karena $X_{t+1} = \mu_{t+1} + e_{t+1}$:

$$\mathbb{E}(X_{t+1}e_{t+1} \mid \mathcal{F}_t) = \mathbb{E}\big((\mu_{t+1} + e_{t+1})e_{t+1} \mid \mathcal{F}_t\big) = \mu_{t+1}\mathbb{E}(e_{t+1}) + \mathbb{E}(e_{t+1}^2) = 0 + \sigma^2.$$

Jadi $\hat{X}_t(2) = -a\hat{X}_t(1) + \alpha + b\sigma^2$. Dengan cara yang sama, untuk $h \geq 2$ pada model ini $\hat{X}_t(h) = -a\hat{X}_t(h-1) + \alpha + b\sigma^2$. Perhatikan bahwa suku bilinear menyumbang $b\sigma^2$, bukan nol.

Kasus X lebih akhir daripada e. Kadang diperlukan $\mathbb{E}(X_{t+2}e_{t+1} \mid \mathcal{F}_t)$ (misalnya untuk suku $X_{t+h-1}e_{t+h-2}$ ketika $h = 3$). Kalikan persamaan X_{t+2} dengan e_{t+1} lalu ambil ekspektasi:

$$\mathbb{E}(X_{t+2}e_{t+1} \mid \mathcal{F}_t) = -a\,\mathbb{E}(X_{t+1}e_{t+1}) + \alpha\mathbb{E}(e_{t+1}) + b\,\mathbb{E}(X_{t+1}e_{t+1}^2) + \mathbb{E}(e_{t+2}e_{t+1}).$$

Suku kedua dan keempat nol. $\mathbb{E}(X_{t+1}e_{t+1}) = \sigma^2$ seperti di atas, dan $\mathbb{E}(X_{t+1}e_{t+1}^2) = \mathbb{E}((\mu_{t+1} + e_{t+1})e_{t+1}^2) = \mu_{t+1}\sigma^2 + \mathbb{E}(e_{t+1}^3) = \hat{X}_t(1)\sigma^2$ (momen ketiga normal bernilai nol). Jadi $\mathbb{E}(X_{t+2}e_{t+1} \mid \mathcal{F}_t) = -a\sigma^2 + b\sigma^2\hat{X}_t(1)$.

12.3 Aturan umum

Untuk suku $X_{t+h-i}e_{t+h-j}$ dalam persamaan X_{t+h}, ekspektasi bersyaratnya mengikuti empat kasus:

Kondisi	$\mathbb{E}(X_{t+h-i}e_{t+h-j} \mid \mathcal{F}_t)$	Alasan
$i \geq h$ dan $j \geq h$	$X_{t+h-i}\, e_{t+h-j}$	keduanya sudah terjadi
$i < h \leq j$	$\hat{X}_t(h-i)\, e_{t+h-j}$	e sudah terjadi, X belum
$j < h$ dan $j < i$	0	e belum terjadi dan lebih akhir daripada X, jadi bebas
$i \leq j < h$	σ^2 jika $i = j$; rekursi seperti contoh di atas jika $i < j$	X bergantung pada e

Untuk model dengan banyak suku, kasus terakhir menghasilkan rantai rekursi yang panjang.

12.4 Alternatif Monte Carlo

Ekspektasi bersyarat dapat dihitung tanpa menurunkan rumus: bangkitkan banyak lintasan masa depan dengan $e_{t+1}, \ldots, e_{t+h} \sim N(0, \hat{\sigma}^2)$ dan data masa lalu tetap, hitung $X_{t+1}, \ldots, X_{t+h}$ dengan (2), lalu ambil rata-rata X_{t+h}. Dengan banyak lintasan, rata-rata ini mendekati $\hat{X}_t(h)$ yang tepat. Untuk Model S, cara ini memberi hasil yang sama dengan nilai yang dilaporkan:

Table 3: *Mean squared error* peramalan $\hat{\sigma}^2(h)$, data sunspot 1921–1955.

h	1	2	3	4	5
Dilaporkan Subba Rao & Gabr (1984)	123.77	337.54	569.79	659.05	718.87
Hitung ulang (Monte Carlo, 20 000 lintasan)	123.77*	337.48	570.75	659.00	720.57

* dihitung tepat dari rekursi galat; nilai peramalan satu langkahnya juga identik dengan yang dilaporkan (24.55, 11.43, 10.08, …).

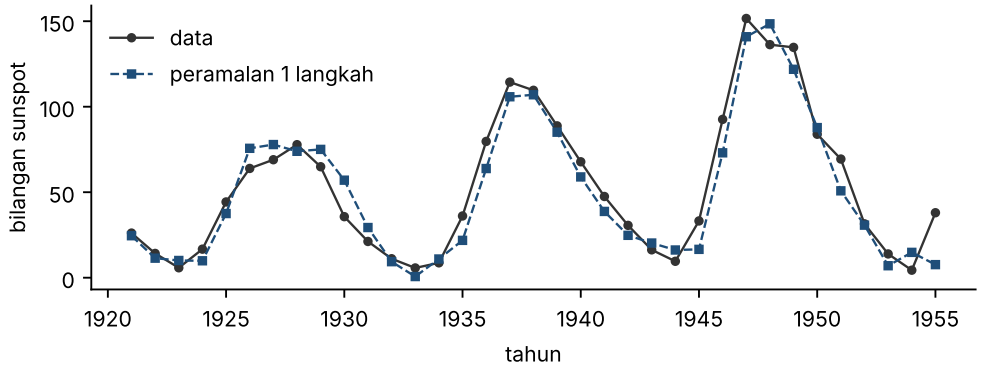


Figure 4: Peramalan satu langkah Model S untuk tahun 1921–1955.

13 Contoh hitungan tangan

Ambil model

$$X_t + aX_{t-1} = \alpha + bX_{t-1}e_{t-1} + e_t,$$

dengan enam data $X = (1.2,\ 0.8,\ 1.9,\ 0.4,\ 1.5,\ 1.1)$, $\gamma = 1$, $n = 5$, dan nilai awal $\boldsymbol{\theta}^{(0)} = (a, b, \alpha) = (-0.4,\ 0.3,\ 0.5)$.

13.1 Rekursi galat

Rumusnya $e_t = X_t + aX_{t-1} - \alpha - bX_{t-1}e_{t-1}$ dengan $e_1 = 0$:

$$
\begin{aligned}
e_2 &= 0.8 + (-0.4)(1.2) - 0.5 - (0.3)(1.2)(0) = 0.8 - 0.48 - 0.5 = -0.1800,\\
e_3 &= 1.9 + (-0.4)(0.8) - 0.5 - (0.3)(0.8)(-0.18) = 1.9 - 0.32 - 0.5 + 0.0432 = 1.1232,\\
e_4 &= 0.4 + (-0.4)(1.9) - 0.5 - (0.3)(1.9)(1.1232) = 0.4 - 0.76 - 0.5 - 0.64022 = -1.5002,\\
e_5 &= 1.5 + (-0.4)(0.4) - 0.5 - (0.3)(0.4)(-1.5002) = 1.5 - 0.16 - 0.5 + 0.18003 = 1.0200,\\
e_6 &= 1.1 + (-0.4)(1.5) - 0.5 - (0.3)(1.5)(1.0200) = 1.1 - 0.6 - 0.5 - 0.45901 = -0.4590.
\end{aligned}
$$

13.2 Turunan rekursif

Seperti di Bagian 4, turunan galat terhadap setiap parameter ditulis dengan simbol ψ:

$$\psi_{t,a} = \frac{\partial e_t}{\partial a}, \qquad \psi_{t,b} = \frac{\partial e_t}{\partial b}, \qquad \psi_{t,\alpha} = \frac{\partial e_t}{\partial \alpha}.$$

Jadi $\psi_{t,a}$ mengukur seberapa besar e_t berubah bila a diubah sedikit, dan seterusnya. Dari (10), dengan semua turunan nol pada $t = 1$:

$$
\begin{aligned}
\psi_{t,a} &= \frac{\partial e_t}{\partial a} = X_{t-1} - bX_{t-1}\frac{\partial e_{t-1}}{\partial a} = X_{t-1} - bX_{t-1}\psi_{t-1,a},\\
\psi_{t,b} &= \frac{\partial e_t}{\partial b} = -X_{t-1}e_{t-1} - bX_{t-1}\frac{\partial e_{t-1}}{\partial b} = -X_{t-1}e_{t-1} - bX_{t-1}\psi_{t-1,b},\\
\psi_{t,\alpha} &= \frac{\partial e_t}{\partial \alpha} = -1 - bX_{t-1}\frac{\partial e_{t-1}}{\partial \alpha} = -1 - bX_{t-1}\psi_{t-1,\alpha},
\end{aligned}
$$

dengan $\psi_{1,a} = \psi_{1,b} = \psi_{1,\alpha} = 0$. Sebagai contoh, turunan terhadap b:

$$
\begin{aligned}
\psi_{2,b} &= \tfrac{\partial e_2}{\partial b} = -(1.2)(0) - (0.3)(1.2)(0) = 0,\\
\psi_{3,b} &= \tfrac{\partial e_3}{\partial b} = -(0.8)(-0.18) - (0.3)(0.8)(0) = 0.1440,\\
\psi_{4,b} &= \tfrac{\partial e_4}{\partial b} = -(1.9)(1.1232) - (0.3)(1.9)(0.1440) = -2.1341 - 0.0821 = -2.2162,\\
\psi_{5,b} &= \tfrac{\partial e_5}{\partial b} = -(0.4)(-1.5002) - (0.3)(0.4)(-2.2162) = 0.6001 + 0.2659 = 0.8660,\\
\psi_{6,b} &= \tfrac{\partial e_6}{\partial b} = -(1.5)(1.0200) - (0.3)(1.5)(0.8660) = -1.5300 - 0.3897 = -1.9198.
\end{aligned}
$$

Setiap baris memakai ψ dari baris sebelumnya; misalnya $\psi_{4,b}$ memakai $\psi_{3,b} = 0.1440$. Jika suku rekursif diabaikan, akan diperoleh $\psi_{6,b} = -1.5300$, yang salah sekitar 20%.

Table 4: Galat dan turunannya pada $\boldsymbol{\theta}^{(0)}$.

t	X_t	e_t	$\psi_{t,a} = \partial e_t/\partial a$	$\psi_{t,b} = \partial e_t/\partial b$	$\psi_{t,\alpha} = \partial e_t/\partial \alpha$
1	1.2	0	0	0	0
2	0.8	−0.1800	1.2000	0.0000	−1.0000
3	1.9	1.1232	0.5120	0.1440	−0.7600
4	0.4	−1.5002	1.6082	−2.2162	−0.5668
5	1.5	1.0200	0.2070	0.8660	−0.9320
6	1.1	−0.4590	1.4068	−1.9198	−0.5806

Pemeriksaan dengan beda hingga. Menghitung ulang e_6 dengan setiap parameter digeser $\pm 10^{-6}$ memberi $\psi_{6,a} = \partial e_6/\partial a \approx 1.406841$, $\psi_{6,b} = \partial e_6/\partial b \approx -1.919753$, $\psi_{6,\alpha} = \partial e_6/\partial \alpha \approx -0.580607$, identik dengan hasil rumus rekursif sampai enam desimal.

13.3 Satu langkah iterasi

Dari tabel, $Q = \sum_{t=2}^{6} e_t^2 = 4.7958$ dan $\hat{\sigma}^2 = Q/5 = 0.9592$. Matriks $\mathbf{J}$ adalah tiga kolom terakhir tabel ($\psi_{t,a}$, $\psi_{t,b}$, $\psi_{t,\alpha}$) untuk $t = 2, \ldots, 6$. Maka

$$\mathbf{J}'\mathbf{J} = \begin{pmatrix} 6.3104 & -6.0117 & -3.5104 \\ -6.0117 & 9.3676 & 1.4542 \\ -3.5104 & 1.4542 & 3.1046 \end{pmatrix}, \qquad \mathbf{J}'\mathbf{e} = \begin{pmatrix} -2.4881 \\ 5.2510 \\ -0.5074 \end{pmatrix}.$$

Contoh satu entri: $(\mathbf{J}'\mathbf{e})_1 = \sum_t \psi_{t,a} e_t = (1.2)(-0.18) + (0.512)(1.1232) + (1.6082)(-1.5002) + (0.207)(1.02) + (1.4068)(-0.459) = -2.4881$. Gradien dan Hessian pendekatan adalah $\mathbf{g} = 2\mathbf{J}'\mathbf{e}$ dan $\mathbf{H} = 2\mathbf{J}'\mathbf{J}$. Menyelesaikan $(\mathbf{J}'\mathbf{J})\boldsymbol{\delta} = \mathbf{J}'\mathbf{e}$ memberi $\boldsymbol{\delta} = (-2.0812,\ -0.4145,\ -2.3226)'$, sehingga

$$\boldsymbol{\theta}^{(1)} = \boldsymbol{\theta}^{(0)} - \boldsymbol{\delta} = (1.6812,\ 0.7145,\ 2.8226)', \qquad Q(\boldsymbol{\theta}^{(1)}) = 3.1364 < 4.7958.$$

Dengan hanya lima galat, langkahnya sangat besar; contoh ini dimaksudkan untuk memeriksa perhitungan, bukan untuk memperoleh dugaan yang bermakna.

14 Contoh iterasi manual Gauss–Newton

Bagian ini menjalankan Algoritma 1 secara manual untuk dua iterasi, lengkap dengan semua perhitungan antara. Agar perhitungannya dapat diikuti dengan tangan, dipakai model dengan dua parameter.

14.1 Data dan model

Sebelas pengamatan berikut dibangkitkan dari $X_t = 0.5X_{t-1} + 0.4X_{t-1}e_{t-1} + e_t$ dengan $e_t \sim N(0,1)$ lalu dibulatkan satu desimal:

t	1	2	3	4	5	6	7	8	9	10	11
X_t	-0.6	-0.2	-1.2	-0.5	0.0	0.1	1.6	1.9	0.8	-0.5	0.4

Model yang diduga (tanpa konstanta), dalam konvensi dokumen ini:

$$X_t + aX_{t-1} = b\,X_{t-1}e_{t-1} + e_t, \qquad \boldsymbol{\theta} = (a, b)',$$

sehingga nilai sebenarnya $a = -0.5$ dan $b = 0.4$. Lag terbesar $\gamma = 1$, jadi $e_1 = 0$ dan $n = N - \gamma = 10$.

Rumus yang dipakai, dari (3) dan (10):

$$e_t = X_t + aX_{t-1} - bX_{t-1}e_{t-1},$$
$$\psi_{t,a} = \frac{\partial e_t}{\partial a} = X_{t-1} - bX_{t-1}\psi_{t-1,a}, \qquad \psi_{t,b} = \frac{\partial e_t}{\partial b} = -X_{t-1}e_{t-1} - bX_{t-1}\psi_{t-1,b},$$

dengan $e_1 = \psi_{1,a} = \psi_{1,b} = 0$.

14.2 Langkah 0: nilai awal

Mulai dari model AR(1) dengan $b = 0$: $X_t = -aX_{t-1} + e_t$. Penduga OLS (regresi tanpa konstanta) adalah

$$a^{(0)} = -\frac{\sum_{t=2}^{11} X_{t-1}X_t}{\sum_{t=2}^{11} X_{t-1}^2} = -\frac{5.08}{9.16} = -0.5546, \qquad b^{(0)} = 0, \qquad \boldsymbol{\theta}^{(0)} = (-0.5546,\ 0)'.$$

14.3 Iterasi pertama ($s = 0$)

Galat dan turunan. Karena $b^{(0)} = 0$, rekursi menjadi sederhana: $e_t = X_t + aX_{t-1}$, $\psi_{t,a} = X_{t-1}$, dan $\psi_{t,b} = -X_{t-1}e_{t-1}$. Misalnya

$$
\begin{aligned}
e_2 &= -0.2 + (-0.5546)(-0.6) = 0.1328, & \psi_{2,b} &= -X_1 e_1 = -(-0.6)(0) = 0,\\
e_3 &= -1.2 + (-0.5546)(-0.2) = -1.0891, & \psi_{3,b} &= -X_2 e_2 = -(-0.2)(0.1328) = 0.0266,\\
e_4 &= -0.5 + (-0.5546)(-1.2) = 0.1655, & \psi_{4,b} &= -X_3 e_3 = -(-1.2)(-1.0891) = -1.3069.
\end{aligned}
$$

Semua baris dirangkum dalam Tabel 5. Kolom-kolom di kanan adalah hasil kali yang diperlukan untuk Q, $\mathbf{J}'\mathbf{J}$, dan $\mathbf{J}'\mathbf{e}$.

Table 5: Iterasi pertama, dihitung pada $\boldsymbol{\theta}^{(0)} = (-0.5546,\ 0)'$.

t	X_t	e_t	$\psi_{t,a}$	$\psi_{t,b}$	e_t^2	$\psi_{t,a}^2$	$\psi_{t,a}\psi_{t,b}$	$\psi_{t,b}^2$	$\psi_{t,a}e_t$	$\psi_{t,b}e_t$
2	−0.2000	0.1328	−0.6000	0.0000	0.0176	0.3600	0.0000	0.0000	−0.0797	0.0000
3	−1.2000	−1.0891	−0.2000	0.0266	1.1861	0.0400	−0.0053	0.0007	0.2178	−0.0289
4	−0.5000	0.1655	−1.2000	−1.3069	0.0274	1.4400	1.5683	1.7080	−0.1986	−0.2163
5	0.0000	0.2773	−0.5000	0.0828	0.0769	0.2500	−0.0414	0.0068	−0.1386	0.0229
6	0.1000	0.1000	0.0000	0.0000	0.0100	0.0000	0.0000	0.0000	0.0000	0.0000
7	1.6000	1.5445	0.1000	−0.0100	2.3856	0.0100	−0.0010	0.0001	0.1545	−0.0154
8	1.9000	1.0127	1.6000	−2.4713	1.0255	2.5600	−3.9540	6.1072	1.6203	−2.5026
9	0.8000	−0.2537	1.9000	−1.9241	0.0644	3.6100	−3.6557	3.7020	−0.4821	0.4882
10	−0.5000	−0.9437	0.8000	0.2030	0.8905	0.6400	0.1624	0.0412	−0.7549	−0.1915
11	0.4000	0.6773	−0.5000	−0.4718	0.4587	0.2500	0.2359	0.2226	−0.3386	−0.3196
Jumlah					6.1427	9.1600	−5.6909	11.7886	0.0000	−2.7632

Menyusun $\mathbf{J}'\mathbf{J}$ dan $\mathbf{J}'\mathbf{e}$. Dari baris jumlah:

$$
\begin{aligned}
Q^{(0)} &= \sum e_t^2 = 6.1427,\\
\mathbf{J}'\mathbf{J} &= \begin{pmatrix} \sum \psi_{t,a}^2 & \sum \psi_{t,a}\psi_{t,b} \\ \sum \psi_{t,a}\psi_{t,b} & \sum \psi_{t,b}^2 \end{pmatrix} = \begin{pmatrix} 9.1600 & -5.6909 \\ -5.6909 & 11.7886 \end{pmatrix},\\
\mathbf{J}'\mathbf{e} &= \begin{pmatrix} \sum \psi_{t,a}e_t \\ \sum \psi_{t,b}e_t \end{pmatrix} = \begin{pmatrix} 0.0000 \\ -2.7632 \end{pmatrix}.
\end{aligned}
$$

Komponen gradien untuk a bernilai nol karena $a^{(0)}$ adalah penduga OLS saat $b = 0$: pada titik itu Q sudah minimum terhadap a. Komponen untuk b tidak nol, jadi Q masih dapat diturunkan dengan mengubah b.

Invers matriks 2×2. Untuk $\mathbf{M} = \begin{pmatrix} p & r \\ r & w \end{pmatrix}$, berlaku $\mathbf{M}^{-1} = \dfrac{1}{pw - r^2}\begin{pmatrix} w & -r \\ -r & p \end{pmatrix}$. Di sini

$$
\det(\mathbf{J}'\mathbf{J}) = (9.1600)(11.7886) - (-5.6909)^2 = 107.9836 - 32.3863 = 75.5973,
$$

$$
(\mathbf{J}'\mathbf{J})^{-1} = \frac{1}{75.5973}\begin{pmatrix} 11.7886 & 5.6909 \\ 5.6909 & 9.1600 \end{pmatrix} = \begin{pmatrix} 0.15594 & 0.07528 \\ 0.07528 & 0.12117 \end{pmatrix}.
$$

Vektor koreksi dan nilai baru.

$$\boldsymbol{\delta}^{(0)} = (\mathbf{J}'\mathbf{J})^{-1}\mathbf{J}'\mathbf{e} = \begin{pmatrix} (0.15594)(0.0000) + (0.07528)(-2.7632) \\ (0.07528)(0.0000) + (0.12117)(-2.7632) \end{pmatrix} = \begin{pmatrix} -0.2080 \\ -0.3348 \end{pmatrix},$$

$$\boldsymbol{\theta}^{(1)} = \boldsymbol{\theta}^{(0)} - \boldsymbol{\delta}^{(0)} = \begin{pmatrix} -0.5546 - (-0.2080) \\ 0 - (-0.3348) \end{pmatrix} = \begin{pmatrix} -0.3466 \\ 0.3348 \end{pmatrix}.$$

14.4 Iterasi kedua ($s = 1$)

Galat dan turunan. Sekarang $b^{(1)} = 0.3348 \neq 0$, sehingga suku rekursif ikut bekerja. Misalnya:

$$\begin{aligned}
e_2 &= -0.2 + (-0.3466)(-0.6) - (0.3348)(-0.6)(0) = 0.0079, \\
e_3 &= -1.2 + (-0.3466)(-0.2) - (0.3348)(-0.2)(0.0079) = -1.1302, \\
e_4 &= -0.5 + (-0.3466)(-1.2) - (0.3348)(-1.2)(-1.1302) = -0.5382, \\
\psi_{3,a} &= X_2 - bX_2\psi_{2,a} = -0.2 - (0.3348)(-0.2)(-0.6) = -0.2402, \\
\psi_{4,a} &= X_3 - bX_3\psi_{3,a} = -1.2 - (0.3348)(-1.2)(-0.2402) = -1.2965, \\
\psi_{3,b} &= -X_2e_2 - bX_2\psi_{2,b} = -(-0.2)(0.0079) - (0.3348)(-0.2)(0) = 0.0016, \\
\psi_{4,b} &= -X_3e_3 - bX_3\psi_{3,b} = -(-1.2)(-1.1302) - (0.3348)(-1.2)(0.0016) = -1.3555.
\end{aligned}$$

Table 6: Iterasi kedua, dihitung pada $\boldsymbol{\theta}^{(1)} = (-0.3466,\ 0.3348)'$.

t	X_t	e_t	$\psi_{t,a}$	$\psi_{t,b}$	e_t^2	$\psi_{t,a}^2$	$\psi_{t,a}\psi_{t,b}$	$\psi_{t,b}^2$	$\psi_{t,a}e_t$	$\psi_{t,b}e_t$
2	−0.2000	0.0079	−0.6000	0.0000	0.0001	0.3600	0.0000	0.0000	−0.0048	0.0000
3	−1.2000	−1.1302	−0.2402	0.0016	1.2772	0.0577	−0.0004	0.0000	0.2714	−0.0018
4	−0.5000	−0.5382	−1.2965	−1.3555	0.2896	1.6809	1.7575	1.8375	0.6977	0.7295
5	0.0000	0.0832	−0.7170	−0.4960	0.0069	0.5141	0.3557	0.2460	−0.0597	−0.0413
6	0.1000	0.1000	0.0000	0.0000	0.0100	0.0000	0.0000	0.0000	0.0000	0.0000
7	1.6000	1.5620	0.1000	−0.0100	2.4398	0.0100	−0.0010	0.0001	0.1562	−0.0156
8	1.9000	0.5087	1.5464	−2.4938	0.2588	2.3914	−3.8565	6.2192	0.7867	−1.2687
9	0.8000	−0.1821	0.9163	0.6199	0.0332	0.8395	0.5680	0.3842	−0.1669	−0.1129
10	−0.5000	−0.7285	0.5546	−0.0203	0.5307	0.3076	−0.0113	0.0004	−0.4040	0.0148
11	0.4000	0.4513	−0.4072	−0.3676	0.2037	0.1658	0.1497	0.1352	−0.1838	−0.1659
Jumlah					5.0500	6.3270	−1.0384	8.8226	1.0930	−0.8618

Pemeriksaan penurunan Q. $Q^{(1)} = 5.0500 < Q^{(0)} = 6.1427$, jadi langkah penuh ($\lambda = 1$) diterima tanpa step-halving.

Menyusun $\mathbf{J}'\mathbf{J}$ dan $\mathbf{J}'\mathbf{e}$.

$$\mathbf{J}'\mathbf{J} = \begin{pmatrix} 6.3270 & -1.0384 \\ -1.0384 & 8.8226 \end{pmatrix}, \qquad \mathbf{J}'\mathbf{e} = \begin{pmatrix} 1.0930 \\ -0.8618 \end{pmatrix},$$

$$\det(\mathbf{J}'\mathbf{J}) = (6.3270)(8.8226) - (-1.0384)^2 = 55.8206 - 1.0783 = 54.7423,$$

$$(\mathbf{J}'\mathbf{J})^{-1} = \frac{1}{54.7423}\begin{pmatrix} 8.8226 & 1.0384 \\ 1.0384 & 6.3270 \end{pmatrix} = \begin{pmatrix} 0.16117 & 0.01897 \\ 0.01897 & 0.11558 \end{pmatrix}.$$

Vektor koreksi dan nilai baru.

$$\boldsymbol{\delta}^{(1)} = \begin{pmatrix} (0.16117)(1.0930) + (0.01897)(-0.8618) \\ (0.01897)(1.0930) + (0.11558)(-0.8618) \end{pmatrix} = \begin{pmatrix} 0.17616 - 0.01635 \\ 0.02073 - 0.09961 \end{pmatrix} = \begin{pmatrix} 0.1598 \\ -0.0789 \end{pmatrix},$$

$$\boldsymbol{\theta}^{(2)} = \boldsymbol{\theta}^{(1)} - \boldsymbol{\delta}^{(1)} = \begin{pmatrix} -0.3466 - 0.1598 \\ 0.3348 - (-0.0789) \end{pmatrix} = \begin{pmatrix} -0.5064 \\ 0.4137 \end{pmatrix}, \qquad Q^{(2)} = 4.7888.$$

14.5 Iterasi berikutnya dan konvergensi

Melanjutkan prosedur yang sama memberi:

s	$a^{(s)}$	$b^{(s)}$	$Q^{(s)}$	perubahan relatif Q
0	-0.5546	0.0000	6.14270	–
1	-0.3466	0.3348	5.05000	1.8×10^{-1}
2	-0.5064	0.4137	4.78883	5.2×10^{-2}
3	-0.5239	0.4126	4.78699	3.8×10^{-4}
4	-0.5237	0.4137	4.78698	2×10^{-6}
5	-0.5238	0.4135	4.78698	$< 10^{-8}$

Iterasi berhenti setelah perubahan relatif Q di bawah 10^{-8}. Dugaan akhirnya $\hat{a} = -0.5238$, $\hat{b} = 0.4136$, dan $\hat{\sigma}^2 = Q/n = 4.78698/10 = 0.4787$, dekat dengan nilai sebenarnya $a = -0.5$ dan $b = 0.4$. Perhatikan pola umumnya: Q turun cepat pada beberapa iterasi pertama, lalu perubahannya mengecil dengan cepat ketika dugaan sudah dekat dengan minimum.

Catatan

Angka di tabel dibulatkan empat desimal. Bila perhitungan diulang dengan angka yang sudah dibulatkan, digit terakhir dapat sedikit berbeda. Dengan hanya 10 galat, dugaan ini tentu sangat tidak presisi; contoh ini dimaksudkan untuk memperlihatkan mekanisme iterasi.

15 Studi simulasi

Data dibangkitkan dari $X_t - 0.4X_{t-1} = 0.5 + 0.3X_{t-1}e_{t-1} + e_t$, yaitu $a = -0.4$, $b = 0.3$, $\alpha = 0.5$, dengan $\sigma^2 = 1$ dan $N = 500$ (100 nilai pertama dibuang agar pengaruh nilai awal hilang). Tabel 7 menunjukkan iterasi Gauss–Newton (langkah penuh) untuk ulangan pertama, mulai dari AR(1) dengan $b = 0$.

Dua pelajaran: (1) bahkan pada model paling sederhana dengan $N = 500$, sekitar 10% pendugaan dari satu nilai awal terjebak di minimum lokal (“minimum lokal” di sini berarti bahwa iterasi yang dimulai dari nilai sebenarnya mencapai Q yang lebih kecil); multi-start mengatasinya. (2) Galat baku (19) untuk b cenderung terlalu kecil (cakupan 91.5%).

16 Verifikasi dengan data nyata

Subba Rao & Gabr (1984) melaporkan model bilinear untuk tiga deret yang datanya juga mereka cantumkan: bilangan sunspot tahunan 1700–1955, jumlah tangkapan lynx Kanada tahunan 1821–

Table 7: Iterasi Gauss–Newton pada satu data simulasi.

Iterasi	a	b	α	$\hat{\sigma}^2$
0	-0.6093	0.0000	0.4976	1.22797
1	-0.4070	0.1683	0.5463	1.01386
2	-0.4197	0.2690	0.4610	0.94040
3	-0.4111	0.2984	0.4624	0.93622
4	-0.4003	0.2929	0.4775	0.93551
5	-0.4003	0.2945	0.4765	0.93549
8	-0.3999	0.2942	0.4771	0.93549

Galat baku (19) pada hasil akhir: 0.038, 0.015, 0.056.

Table 8: Monte Carlo 200 ulangan ($N = 500$). "SE" adalah rata-rata galat baku (19).

	$a = -0.4$	$b = 0.3$	$\alpha = 0.5$
Satu nilai awal (AR, $b = 0$)			
Rata-rata dugaan	-0.408	0.283	0.510
Simpangan baku dugaan	0.053	0.052	0.056
Peluang cakupan selang kepercayaan 95%	0.875	0.795	0.960
Dugaan b meleset > 0.1	21 dari 200 (19 di antaranya minimum lokal)		
Multi-start, $b^{(0)} \in \{-0.4, -0.2, 0, 0.2, 0.4\}$			
Rata-rata dugaan	-0.397	0.300	0.509
Simpangan baku dugaan	0.040	0.020	0.058
Rata-rata SE	0.038	0.010	0.058
Peluang cakupan selang kepercayaan 95%	0.955	0.915	0.955
Dugaan b meleset > 0.1	2 dari 200		

1934, dan pengangguran bulanan Jerman Barat 1948–1980. Metode di dokumen ini diimplementasikan secara independen dan dijalankan pada data yang sama; hasilnya dibandingkan dengan yang mereka laporkan.

16.1 Model S: sunspot

Data 1700–1920 ($N = 221$), $\gamma = 10$, $n = 211$. Lag AR $\mathcal{K} = \{1, 2, 9\}$ dan tujuh suku bilinear:

$$X_t + a_1 X_{t-1} + a_2 X_{t-2} + a_9 X_{t-9} = \alpha + \sum_{(i,j)\in\mathcal{B}} b_{ij} X_{t-i} e_{t-j} + e_t,$$

dengan $\mathcal{B} = \{(2,1), (8,1), (1,3), (4,3), (1,6), (2,4), (3,2)\}$. Gauss–Newton dari model AR dengan semua $b = 0$ konvergen ke:

16.2 Model L1: logaritma lynx

Data $\log_{10}$ 1821–1920 ($N = 100$), $\gamma = 12$, $n = 88$, lag AR $\{1, 2, 3, 4, 9, 12\}$, dan suku bilinear $(3, 9)$, $(9, 9)$, $(6, 2)$, $(1, 1)$, $(2, 7)$, $(4, 2)$. Dengan menambahkan suku satu per satu dalam urutan itu, hasilnya $\hat{\sigma}^2 = 0.02227$ dan NAIC $= -3.509$ (dilaporkan: 0.0223 dan -3.508). Koefisien hasil hitung ulang, semuanya dalam ± 0.005 dari yang dilaporkan:

$$\hat{a} = (-0.771,\ 0.090,\ -0.082,\ 0.262,\ -0.225,\ 0.246),$$
$$\hat{b} = (-0.790,\ 0.480,\ 0.391,\ 0.134,\ 0.080,\ -0.322), \qquad \hat{\alpha} = 1.492.$$

Table 9: Model S: nilai yang dilaporkan dan hasil hitung ulang.

Parameter	Dilaporkan	Hitung ulang	SE (19)	t
a_1	-1.5012	-1.5012	0.0439	-34.2
a_2	0.7670	0.7670	0.0452	17.0
a_9	-0.1152	-0.1152	0.0211	-5.5
$b_{2,1}$	$-0.1458^{\dagger}$	-0.014575	0.0010	-14.3
$b_{8,1}$	0.006312	0.006312	0.0010	6.6
$b_{1,3}$	-0.007152	-0.007152	0.0009	-7.9
$b_{4,3}$	$-006047^{\dagger}$	0.006047	0.0012	4.9
$b_{1,6}$	0.003619	0.003619	0.0007	4.9
$b_{2,4}$	0.004334	0.004333	0.0012	3.7
$b_{3,2}$	0.001782	0.001781	0.0015	1.2
α	6.886	6.886	1.48	4.6
$\hat{\sigma}^2$ / NAIC	124.33 / 4.927	124.33 / 4.927		

† salah cetak; lihat Bagian 17.

16.3 Model L2: lynx asli

Data asli 1821–1920, $\gamma = 10$, $n = 90$, lag AR $\{1, 2, 7, 8\}$, dan tujuh suku bilinear. Data dibagi 100 sebelum pendugaan agar perhitungan stabil (lihat Bagian 18), lalu koefisien dikembalikan ke skala asal. Dengan suku ditambahkan berurutan $(1,1), (3,7), (7,6), (3,5), (4,1), (9,10), (8,10)$, diperoleh

$$X_t - 1.2601X_{t-1} + 0.6559X_{t-2} + 0.1572X_{t-7} - 0.3375X_{t-8} = 343.6 + \sum b_{ij}X_{t-i}e_{t-j} + e_t,$$

dengan $\hat{\sigma}^2 = 477\,946$ (dilaporkan $477\,964.68$) dan ketujuh koefisien b cocok sampai dua angka penting, misalnya $b_{8,10} = -4.15 \times 10^{-4}$ (dilaporkan -4.151×10^{-4}). Jika urutan penambahan dibalik, pendugaan berakhir di minimum lain ($\hat{\sigma}^2 = 486\,637$) yang tidak invertibel.

16.4 Yang belum diverifikasi

Model untuk data pengangguran tidak dihitung ulang. Data tersebut perlu ditransformasi dengan selisih biasa dan selisih musiman 12 bulan, dan modelnya memuat sebelas suku bilinear dengan koefisien berorde 10^{-5}–10^{-6}.

17 Catatan atas angka yang tercetak di buku

Saat menghitung ulang, ditemukan beberapa angka yang tercetak keliru atau membingungkan di Subba Rao & Gabr (1984). Model yang dimaksud adalah Model S, L1, dan L2 di Bagian 16.

18 Jebakan numerik dan rekomendasi

1. **Minimum lokal.** $Q(\boldsymbol{\theta})$ tidak cembung. Gunakan penambahan suku bertahap dan multi-start untuk b.
2. **Ketergantungan pada urutan.** Pada Model L2, urutan penambahan suku menentukan minimum yang dicapai. Bandingkan hasil dari beberapa urutan dan pilih Q terkecil yang invertibel.

Table 10: Angka tercetak dan nilai yang benar.

Lokasi	Tercetak	Seharusnya dan buktinya
Model S	$b_{2,1} = -0.1458$	-0.01458; dengan angka tercetak rekursi galat meledak.
Model S	$b_{4,3} = -006047$	$+0.006047$; $\hat{\sigma}^2 = 124.33$ hanya tercapai dengan tanda positif.
Subset AR sunspot	$a_9 = -0.1450$	-0.1500 dari OLS; $\hat{\sigma}^2 = 203.21$ identik dengan yang dilaporkan.
Model L1	$\alpha = -1.48629$	$+1.486$; konsisten dengan $\alpha \approx \bar{X}(1 + \sum a_k)$ (Bagian 7).
Model L1	$-b_{4,2}X_{t-4}e_{t-2}$ dengan $b_{4,2} = -0.3212$	tanda minus tercetak dua kali; koefisien efektifnya -0.3212.
Model L2	"$X(t) = 1.2598X(t-1) + \ldots$"	dalam konvensi dokumen ini: $X_t - 1.2598X_{t-1} + 0.6548X_{t-2} + 0.1564X_{t-7} - 0.3392X_{t-8} - 336.2 = \ldots$
Data lynx	1867: 4245; 1871: 353	dataset `lynx` bawaan R memakai 4254 dan 358; kedua versi memberi hasil hampir sama.
Uji normalitas	$\mathrm{Var}(G_1) = 6\sum \rho^2$	$\frac{6}{N}\sum \rho^2$; demikian pula untuk G_2 (Bagian 11).

3. **Invertibilitas.** Periksa setiap model kandidat dengan (20). Tanpa pemeriksaan ini, pemilihan otomatis cenderung memilih model tidak invertibel dengan $\hat{\sigma}^2$ semu yang kecil (Gambar 3).

4. **Skala data.** Jika X_t bernilai ratusan atau ribuan, koefisien b menjadi sangat kecil dan matriks $\mathbf{J}'\mathbf{J}$ sulit dibalik secara numerik. Skalakan data dengan $\tilde{X}_t = X_t/c$. Karena galat juga terskala, $\tilde{e}_t = e_t/c$, dan persamaan model menjadi $\tilde{X}_t + \sum a_k \tilde{X}_{t-k} = \alpha/c + \sum (b_{ij}c)\tilde{X}_{t-i}\tilde{e}_{t-j} + \tilde{e}_t$. Jadi a_k tidak berubah, $\alpha = c\,\tilde{\alpha}$, $b_{ij} = \tilde{b}_{ij}/c$, dan $\sigma^2 = c^2\tilde{\sigma}^2$.

5. **Kontrol ukuran langkah.** Pakai step-halving atau Levenberg–Marquardt, dan tandai kegagalan bila Q tak hingga.

6. **Aturan berhenti pemilihan model.** Tetapkan aturan yang tegas, misalnya berhenti saat AIC naik.

7. **Inferensi.** Laporkan galat baku (19) sebagai pendekatan; gunakan bootstrap bila perlu kesimpulan formal.

8. **Uji normalitas.** Gunakan $\mathrm{Var}(G_1) = \frac{6}{N}\sum \rho^2$.

Ringkasan isi fungsi pendugaan yang perlu dibangun

1. Rekursi galat (3) dan $Q(\boldsymbol{\theta})$.
2. Turunan rekursif (10), termasuk perluasan MA bila diperlukan.
3. Iterasi Gauss–Newton (17) dengan kontrol ukuran langkah (Algoritma 1).
4. Nilai awal dari OLS model AR; multi-start untuk b.
5. AIC/NAIC (18) dengan $n = N - \gamma$ yang sama untuk semua model.
6. Pemilihan subset AR (pencarian menyeluruh) dan penambahan suku bilinear bertahap.
7. Galat baku (19) dan diagnostik invertibilitas (20).
8. Uji residual W, u_1, u_2 (dengan $1/N$).
9. Peramalan satu langkah (rekursi) dan h langkah (ekspektasi bersyarat atau Monte Carlo).
10. Uji fungsi: harus mereproduksi Model S, L1, dan L2.

Daftar Pustaka

- Grahn, T. (1995). A conditional least squares approach to bilinear time series estimation. *J. Time Series Anal.* 16, 509–529.
- Granger, C. W. J. & Andersen, A. P. (1978). On the invertibility of time series models. *Stoch. Proc. Appl.* 8, 83–92.
- Ling, S., Peng, L. & Zhu, F. Inference for a special bilinear time series model. arXiv:1405.3029.
- Lomnicki, Z. A. (1961). Tests for departure from normality in the case of linear stochastic processes. *Metrika* 4, 37–62.
- Marquardt, D. W. (1963). An algorithm for least squares estimation of nonlinear parameters. *J. SIAM* 11, 431–441.
- Quinn, B. G. (1982). Stationarity and invertibility of simple bilinear models. *Stoch. Proc. Appl.* 12, 225–230.
- Subba Rao, T. (1981). On the theory of bilinear time series models. *J. R. Statist. Soc. B* 43, 244–255.
- Subba Rao, T. & Gabr, M. M. (1984). *An Introduction to Bispectral Analysis and Bilinear Time Series Models.* Lecture Notes in Statistics 24, Springer.